

## บทที่ 2

### ทฤษฎีและงานวิจัยเกี่ยวข้อง

บทนี้นำเสนอทฤษฎีและงานวิจัยที่เกี่ยวข้องกับ ระบบตรวจจับการล้มอัจฉริยะด้วยปัญญาประดิษฐ์ และการระบุพิกัด 3 มิติจากคลื่นไวไฟ โดยเนื้อหาทั้งหมดจะเป็นพื้นฐานสำคัญในการออกแบบและพัฒนา ระบบตรวจจับการล้มที่นำเสนอในบทถัดไป

#### 2.1 ทฤษฎีการหักล้างสัญญาณพื้นหลังและการแยกสัญญาณการเคลื่อนไหวของมนุษย์จากคลื่นไวไฟ (WiFi CSI Background Subtraction & Dynamic Motion Isolation)

2.1.1 แบบจำลองช่องสัญญาณและการแพร่กระจายหลายเส้นทาง (CSI Channel & Multipath Propagation Model)

ในระบบการสื่อสารไร้สายมาตรฐาน IEEE 802.11 (WiFi) สัญญาณคลื่นวิทยุจะถูกส่งผ่านกลไกการกล้ำสัญญาณแบบหลายพาหะย่อยเชิงตั้งฉาก (Orthogonal Frequency Division Multiplexing: OFDM) ข้อมูลสถานะช่องสัญญาณ (Channel State Information: CSI) ที่ฝั่งตัวรับสัญญาณวัดได้ คือค่าตอบสนองความถี่ของช่องสัญญาณ (Channel Frequency Response: CFR) ซึ่งเป็นผลรวมของการซ้อนทับกันของคลื่นวิทยุจากเส้นทางการแพร่กระจายหลายเส้นทาง (Multipath Propagation) จำนวน  $L$  เส้นทาง ทางคณิตศาสตร์ ข้อมูล CFR ณ สับแคร์เรียร์ลำดับที่  $k$  ที่เวลาการรับส่งข้อมูล  $t(m)$  สามารถเขียนแทนด้วยสมการ :

$$H(k, m) = \sum_{l=0}^{L-1} \alpha_l(k, m) e^{-j2\pi f(k)\tau_l} \cdot e^{j2\pi t(m)\nu_l}$$

1)  $\alpha_l(k, m)$  คือ ค่าการลดทอนของสัญญาณ (Attenuation) ในเส้นทางการแพร่กระจายที่  $l$  ณ สับแคร์เรียร์ลำดับที่  $k$  ที่เวลา  $t(m)$

2)  $\tau_l$  คือ เวลาหน่วงในการเดินทางของคลื่นสัญญาณ (Propagation Delay) ในเส้นทาง  $l$

3)  $\nu_l$  คือ ความถี่เลื่อนดอปเปลอร์ (Doppler Frequency Shift) ที่เกิดขึ้นจากการเคลื่อนไหวของวัตถุหรือมนุษย์ในเส้นทางที่  $l$

4)  $f(k)$  คือ ความถี่พาหะย่อยของสับแคร้เรียร์ลำดับที่  $k$

เมื่อนำข้อมูล CFR ไปผ่านการแปลงฟูเรียร์ไม่ต่อเนื่องแบบผกผัน (Inverse Discrete Fourier Transform: IDFT) ขนาด  $N$  จุด จะได้ค่าผลตอบสนองเชิงอิมพัลส์ของช่องสัญญาณ (Channel Impulse Response: CIR) ซึ่งสะท้อนคุณลักษณะทางกายภาพของเส้นทางสัญญาณในโดเมนเวลา-ความหน่วง (Time-Delay Domain) :

$$h(n, m) = \frac{1}{\sqrt{N}} \sum_{k=0}^{N-1} \sum_{l=0}^{L-1} \alpha_l(k, m) e^{-j2\pi f(k)\tau_l} \cdot e^{j2\pi t(m)v_l} \cdot e^{j\frac{2\pi}{N}nk}, \quad n = 0, 1, \dots, N-1$$

2.1.2 การคำนวณผลต่างเวกเตอร์เพื่อหักล้างสัญญาณสะท้อนสถิต (Vector-based Background Subtraction & Differential Residuals)

ในสภาพแวดล้อมภายในห้อง คลื่นสัญญาณ WiFi จะเดินทางผ่านแนวสายตาตรง (Line-of-Sight: LOS) และสะท้อนกับวัตถุที่อยู่หนึ่ง เช่น ผนัง ประตู หน้าต่าง พื้นกระเบื้อง และกระจกเงา เกิดเป็นองค์ประกอบสัญญาณพื้นหลังสถิต (Static Environmental Component) ในขณะที่การเคลื่อนไหวของมนุษย์จะสร้าง เส้นทางสัญญาณสะท้อนแบบพลวัต (Dynamic Multipath Component)


1) การประมาณค่าสัญญาณพื้นหลังสถิต ( $\tilde{\mathbf{h}}_0$ ) ในสภาวะที่ไม่มีเป้าหมายเคลื่อนไหว ข้อมูล CIR พื้นหลังสามารถหาได้จากการหาค่าเฉลี่ยของข้อมูล CIR จำนวน  $M$  ช่วงเวลา เพื่อลดทอนสัญญาณรบกวนสุ่มในการวัด

$$\tilde{\mathbf{h}}_0(n) = \frac{1}{M} \sum_{m=1}^M h(n, m)$$

2) การสกัดสัญญาณการเคลื่อนไหวของเป้าหมาย ( $\mathbf{h}_{\text{target}}$ ) เมื่อมีบุคคลเคลื่อนไหวอยู่ในพื้นที่ สัญญาณ CIR ที่วัดได้ ( $\mathbf{h}_1$ ) จะประกอบด้วยสัญญาณพื้นหลังสถิตรวมกับสัญญาณสะท้อนจากร่างกายมนุษย์ การหักล้างสัญญาณพื้นหลังจะดำเนินการผ่านการลบทางเวกเตอร์ (Vector Subtraction)


$$\mathbf{h}_{\text{target}} = \mathbf{h}_1 - \mathbf{h}_0$$

- กรณีเป้าหมายสร้างเส้นทางสะท้อนใหม่ สัญญาณ LOS และสัญญาณสะท้อนจากโครงสร้างสถิตเดิมจะถูกหักล้างออกไป เหลือเพียงยอดคลื่นสะท้อนใหม่ที่เกิดจากร่างกายมนุษย์



รูปที่ 2.1 (อ้างอิง: Yang et al., 2026, หน้า 3–4, รูปที่ 1(b))

- กรณีเป้าหมายบดบังเส้นทางเดิม การบดบังแนวสายตาตรง (LOS) หรือเส้นทางสะท้อนสถิต จะทำให้เกิดการกลับซ้ำของเฟสและทิ้งค่าเศษเหลือเชิงอนุพันธ์ (Differential Residuals) ของการรบกวนคลื่นไว้ใน  $h_{\text{target}}$




รูปที่ 2.2 (อ้างอิง: Yang et al., 2026, หน้า 3–4, รูปที่ 1(c)–(d))

### 2.1.3 การชดเชยความคลาดเคลื่อนจากการซิงโครไนซ์ (Synchronization Residuals & Compensation Pipeline)


ในอุปกรณ์ WiFi ทัวไป (Bistatic Configuration) ตัวส่งและตัวรับไม่ได้ใช้สัญญาณนาฬิกาเดียวกัน จึงเกิดความคลาดเคลื่อนหลัก 3 ประการ

- 1) Timing Offset (TO:  $\tau_\Delta$ ) ความคลาดเคลื่อนของเวลาเริ่มต้นในการสุ่มตัวอย่าง
- 2) Timing Drift (TD:  $\Delta\tau_m$ ) การเลื่อนลอยของสัญญาณนาฬิกาตามเวลา ซึ่งส่งผลให้ CIR เกิดการเลื่อนตำแหน่งเชิงวงรอบ (Cyclic Shift) ขนาด  $\delta_m = k\Delta f\Delta\tau_m$  และเกิดการเลื่อนเฟสแบบสุ่ม  $\Delta\phi_m = 2\pi\Delta f_{\text{CFO},m}\Delta\tau_m$
- 3) Carrier Frequency Offset (CFO:  $\Delta f_{\text{CFO},m}$ ) ความคลาดเคลื่อนของความถี่ออสซิลเลเตอร์

ผลกระทบหากไม่ชดเชยสัญญาณเฟสของสัญญาณ CIR จะเกิดการกระจายตัวแบบสุ่มและกลับขั้วเฟส ทำให้เมื่อนำ CIR หลายชุดมาหาค่าเฉลี่ย  $\tilde{\mathbf{h}}_0$  สัญญาณจะหักล้างกันเองจนแอมพลิจูดลู่เข้าสู่ศูนย์ ( $\tilde{\mathbf{h}}_0 \rightarrow 0$ ) ทำให้ไม่สามารถสกัดสัญญาณพื้นหลังที่ถูกต้องได้



รูปที่ 2.3 (อ้างอิง: Yang et al., 2026, หน้า 4, หัวข้อ 3.3)



รูปที่ 2.4 (อ้างอิง: Yang et al., 2026, หน้า 4, หัวข้อ 3.3)

#### 2.1.4 การแปลงข้อมูลกลับสู่โดเมนความถี่สำหรับการประมวลผลด้วย AI (CFR Feature Reconstruction)

เมื่อได้ข้อมูล  $\mathbf{h}_{\text{target}}$  ผ่านการหักล้างสัญญาณพื้นหลังแล้ว ข้อมูลจะถูกแปลงกลับเป็น Channel Frequency Response (CFR) ผ่านการแปลง Downsampled DFT เพื่อควบคุมขนาดมิติของข้อมูล จากนั้นทำการจัดเรียงส่วนจริง (In-phase: I) และส่วนจินตภาพ (Quadrature: Q) ของทุกสายอากาศและสับแคร่เรียร์ให้เป็นเมทริกซ์  $\mathbf{CSI}_{\text{sample}} \in \mathbb{R}^{W \times 2M}$  (โดย  $W = N_{tx} \times N_{rx} \times K$ ) เพื่อใช้เป็นข้อมูลนำเข้าของโครงข่ายประสาทเทียมต่อไป

## 2.2 ทฤษฎีการปรับเทียบเฟสและการกำจัดความคลาดเคลื่อนทางฮาร์ดแวร์ในเครื่องรับส่งสัญญาณวิทยุ (Phase Offset Calibration in RF Transceivers)

### 2.2.1 สาเหตุและประเภทของความคลาดเคลื่อนทางเฟสในระบบรับส่งสัญญาณคลื่นวิทยุ (Classification of Phase Offsets)

ในการวัดค่าเฟสของสัญญาณคลื่นพาหะด้วยวงจรรับสัญญาณแบบควอดราเจอร์ซูเปอร์เฮเทอโรไดน์ (Quadrature Superheterodyne Receiver) เพื่อนำไปประยุกต์ใช้ในการระบุพิกัด 3 มิติ

ความแม่นยำสูง (Precision 3D Localization) ค่าเฟสที่วัดได้จริงจะได้รับผลกระทบจากความคลาดเคลื่อนของฮาร์ดแวร์ภายในระบบ ซึ่งแบ่งออกเป็น 3 ประเภทหลัก

1) ความคลาดเคลื่อนของเฟสแบบแปรผันตามเวลา (Time-Varying Phase Offsets) เกิดจากความคลาดเคลื่อนของความถี่คลื่นพาหะ (Carrier Frequency Offset: CFO) และความคลาดเคลื่อนของความถี่ในการสุ่มตัวอย่าง (Sampling Frequency Offset: SFO) อันเนื่องมาจากออสซิลเลเตอร์ท้องถิ่น (Local Oscillator: LO) ของฝั่งส่งและฝั่งรับไม่มีการใช้อ้างอิงความถี่ร่วมกัน ทำให้เกิดการเลื่อนของเฟสเชิงเส้นตามเวลา

2) ความคลาดเคลื่อนของเฟสแบบคงที่เชิงระบบ (Time-Invariant Systematic Phase Offsets) เกิดจากความไม่เท่ากันของเวลาหน่วงในวงจรฟรอนต์เอนด์ (RF Frontend Hardware Delays) ของสายอากาศแต่ละช่องสัญญาณ ( $T_{Tx}, T_{Rx}$ ) ซึ่งก่อให้เกิดค่าชดเชยเฟสคงที่  $\theta_{Tx} = 2\pi f_{LO} T_{Tx}$  และ  $\theta_{Rx} = 2\pi f_{LO} T_{Rx}$

3) ความคลาดเคลื่อนของเฟสแบบสุ่มคงที่ (Time-Invariant Random Phase Offsets) เกิดจากเฟสเริ่มต้นที่ไม่แน่นอนและไม่สามารถทำซ้ำได้ (Non-repeatable Initial Phase) ของวงจรถักล็อกเฟส (Phase-Locked Loop: PLL) ในตัวสังเคราะห์ความถี่ของแต่ละช่องสัญญาณ ซึ่งค่าเฟสเริ่มต้นนี้ ( $\theta_{LO,Tx}, \theta_{LO,Rx}$ ) จะเปลี่ยนแปลงแบบสุ่มทุกครั้งที่มีการรีบูตหรือเริ่มการทำงานของอุปกรณ์ใหม่ แม้ว่าอุปกรณ์จะใช้อ้างอิงความถี่เดียวกันก็ตาม

2.2.2 แบบจำลองการคำนวณเฟสและการแปลงเชิงเส้นสำหรับ CFO/SFO (Phase Calculation & Linear Transformation)

ในโครงสร้างภาครับแบบซูเปอร์เฮเทอโรไดน์ สัญญาณแถบฐาน (Baseband) จะถูกมอดูเลตกับสัญญาณความถี่กลาง (Intermediate Frequency: IF) และอัปคอนเวิร์ตด้วยความถี่  $f_{LO}$  ส่งผ่านช่องสัญญาณไร้สายที่มีการหน่วงเฟส  $\theta_{air}$  ค่าเฟสรวมที่วัดได้จากสัญญาณดิจิทัล IF ผ่านฟังก์ชัน atan2 สามารถเขียนแทนด้วยสมการ

$$\theta_{total} \approx \theta_{Tx} + \theta_{air} + \theta_{Rx} + \theta_{LO,Rx} - \theta_{LO,Tx}$$

สำหรับการกำจัดความคลาดเคลื่อนแบบแปรผันตามเวลาที่เกิดจาก CFO และ SFO ในระบบมัลติเพล็กซ์แบบ OFDM หรือระบบหลายช่องสัญญาณ งานวิจัยในอดีตได้ใช้คุณสมบัติความสัมพันธ์เชิงเส้นระหว่างเฟสกับเวลาและดัชนีสับแครี่เรียร์ (Linear Phase-Time and Phase-Subcarrier

Relationship) ในการทำ การแปลงเชิงเส้นและการประมาณค่าเชิงเส้น (Linear Transformation / Linear Fitting) เช่น Linear Minimum Mean Square Error (L-MMSE) เพื่อหักล้างความชันของเฟสที่เกิดจาก CFO/SFO อย่างไรก็ตาม การกำจัดความชันเชิงเส้นของ CFO/SFO จะยังคงหลงเหลือค่าคงที่ของเฟสที่ไม่ทราบค่า ซึ่งรวมอยู่กับความคลาดเคลื่อนของเฟสเริ่มต้นแบบสุ่ม ( $\theta_{LO}$ ) และความคลาดเคลื่อนเชิงระบบของฟรอนต์เอนด์ ( $\theta_{Rx}$ )

2.2.3 ทฤษฎีการปรับเทียบเฟสด้วยเฟสผลต่างและโมดูลเชื่อมต่อตัวแบ่งสัญญาณ (Differential Phase and SCM Calibration Method)

เมื่อทำการวัดเฟสผลต่างระหว่างสายอากาศตัวรับสองชุด (Rx1 และ Rx2) ที่รับสัญญาณจากตัวส่งเดียวกัน (Condition 1) สัญญาณเฟสผลต่าง  $\theta_{Rx12}$  จะมีรูปแบบดังสมการ

$$\theta_{Rx12} = \theta_{total,Rx1} - \theta_{total,Rx2} = (\theta_{air,Rx1} - \theta_{air,Rx2}) + (\theta_{LO,Rx1} - \theta_{LO,Rx2}) + (\theta_{Rx1} - \theta_{Rx2})$$

เพื่อกำจัดค่า  $(\theta_{LO,Rx1} - \theta_{LO,Rx2})$  และ  $(\theta_{Rx1} - \theta_{Rx2})$  โดยไม่ต้องพึ่งพาทรัพยากรแบนด์วิดท์ขนาดใหญ่หรือการประมวลผลเชิงการหาค่าเหมาะสมที่สุด (Optimization) Xu & Kan (2023) ได้เสนอกระบวนการปรับเทียบ 3 ขั้นตอน

1) ขั้นตอนที่ 1: การวัดค่าโมดูลตัวแบ่งสัญญาณ (Splitter-Connection Module: SCM Measurements) ทำการวัดค่าผลต่างเฟสคงที่ของอุปกรณ์ต่อพ่วงภายนอก  $(\theta_{SCM,out,m} - \theta_{SCM,out,n})$  และผลต่างเชิงระบบของฟรอนต์เอนด์  $(\theta_{Rxm} - \theta_{Rxn})$  เพียงครั้งเดียวผ่านการสลับพอร์ต (Port Swapping) บนคู่ตัวรับที่ใช้ LO ร่วมกัน

2) ขั้นตอนที่ 2: การวัดความคลาดเคลื่อนของเฟสโดยตรง (Direct Phase Offset Measurements) ส่งสัญญาณผ่านวงจร SCM ภายนอกเพื่อวัดค่าผลต่างเฟสที่ไม่พึงประสงค์  $(\theta_{nonideal,mn})$  ของแต่ละคู่ตัวรับที่มี LO แยกอิสระ

$$\theta_{nonideal,mn} = \theta_{Rxmn,step II} - (\theta_{SCM,out,m} - \theta_{SCM,out,n})$$

3) ขั้นตอนที่ 3: การหักล้างและชดเชยเฟส (Phase Offset Correction) สลับการส่งสัญญาณไปยังช่องสัญญาณไร้สายจริง จากนั้นนำค่า  $\theta_{nonideal,mn}$  ที่วัดได้จากขั้นตอนที่ 2 มาลบออกจากเฟสผลต่างที่วัดได้ในช่องสัญญาณไร้สาย  $(\theta_{Rxmn,step III})$

$$\theta_{\text{air,Rx}m} - \theta_{\text{air,Rx}n} = \theta_{\text{Rx}mn,\text{step III}} - \theta_{\text{nonideal},mn}$$

#### 2.2.4 ประสิทธิภาพของการปรับเทียบเฟสและความแม่นยำในการระบุพิกัด (Calibration Performance & Ranging Accuracy)

ผลการทดสอบเชิงประจักษ์บนแพลตฟอร์ม Software Defined Radio (USRP B210) ยืนยันว่า กระบวนการปรับเทียบเฟสสามารถลดความผันแปรของเฟสที่เกิดจากการรีบูตเครื่องให้มีค่าเบี่ยงเบนมาตรฐานน้อยกว่า 2 องศา (Standard Deviation  $< 2^\circ$ ) ซึ่งเทียบเท่ากับความคลาดเคลื่อนในการวัดระยะทางในอากาศที่ความถี่ 1.8 GHz เพียง 0.9 มิลลิเมตร (0.9 mm Ranging Accuracy) ซึ่งมอบความเสถียรและความแม่นยำสูงสำหรับการนำไปประยุกต์ใช้ในระบบระบุพิกัดและการตรวจจับการเคลื่อนไหว 3 มิติ

### 2.3 ข้อมูลสถานะช่องสัญญาณวิทยุและผลตอบสนองความถี่ของช่องสัญญาณ (Channel State Information & Channel Frequency Response)

#### 2.3.1 นิยามและแนวคิดพื้นฐานของข้อมูลสถานะช่องสัญญาณ (Definition and Fundamentals of CSI)

ในระบบเครือข่ายไร้สายมาตรฐาน IEEE 802.11 (WiFi) ข้อมูลสถานะช่องสัญญาณ (Channel State Information: CSI) เป็นข้อมูลระดับชั้นกายภาพ (Physical Layer: PHY) ที่บ่งบอกถึงคุณสมบัติการแพร่กระจายของคลื่นวิทยุระหว่างสายอากาศตัวส่ง (Transmitter: Tx) และสายอากาศตัวรับ (Receiver: Rx) ซึ่งมีความละเอียดและเสถียรมากกว่าค่าบ่งชี้ความแรงของสัญญาณที่ได้รับ (Received Signal Strength Indicator: RSSI) ในระดับชั้น MAC เนื่องจาก RSSI เป็นเพียงค่าสเกลาร์รวมที่สูญเสียมิติของความถี่และเฟส ในระบบ WiFi ที่ใช้เทคโนโลยี Orthogonal Frequency Division Multiplexing (OFDM) สัญญาณจะถูกแบ่งออกเป็นหลายพาหะย่อย (Subcarriers) ข้อมูล CSI ที่ตัวรับสกัดได้จากลำดับฝึกฝน (Pilot/Training Sequences) ในแต่ละแพ็กเก็ต คือค่า ผลตอบสนองความถี่ของช่องสัญญาณ (Channel Frequency Response: CFR) ซึ่งสะท้อนผลกระทบของการลดทอน (Attenuation) การเลื่อนเฟส (Phase Shift) และการแพร่กระจายหลายเส้นทาง (Multipath Propagation) ในแต่ละพาหะย่อยอย่างละเอียด

### 2.3.2 แบบจำลองทางคณิตศาสตร์ของผลตอบสนองความถี่ช่องสัญญาณ (Mathematical Model of CFR)

เมื่อคลื่นวิทยุเดินทางจากตัวส่งไปยังตัวรับ คลื่นจะเดินทางผ่านเส้นทางการแพร่กระจายหลายเส้นทาง (Multipath Paths) จำนวน  $L$  เส้นทาง ซึ่งประกอบด้วยเส้นทางแนวสายตาตรง (Line-of-Sight: LOS) และเส้นทางสะท้อนจากวัตถุต่าง ๆ ในสภาพแวดล้อมรวมถึงร่างกายมนุษย์ ค่า CFR ณ สับแคร่เรียร์ลำดับที่  $k$  ที่เวลาการสุ่มตัวอย่าง  $t(m)$  สามารถจำลองเชิงคณิตศาสตร์ได้ดังสมการ

$$H(k, m) = \sum_{l=0}^{L-1} \alpha_l(k, m) e^{-j2\pi f(k)\tau_l} \cdot e^{j2\pi t(m)\nu_l}$$

1)  $k \in \{0, 1, \dots, K-1\}$  คือ ดัชนีของสับแคร่เรียร์ โดยมีจำนวนสับแคร่เรียร์ทั้งหมด  $K$  ชุด

2)  $f(k)$  คือ ความถี่ของสับแคร่เรียร์ลำดับที่  $k$

3)  $t(m)$  คือ เวลา ณ ขณะที่รับแพ็กเก็ตลำดับที่  $m$

4)  $\alpha_l(k, m)$  คือ สัมประสิทธิ์การลดทอนของสัญญาณเชิงซ้อนในเส้นทางที่  $l$

5)  $\tau_l$  คือ เวลาหน่วงในการแพร่กระจายสัญญาณ (Propagation Delay) ของเส้นทางที่  $l$

6)  $\nu_l$  คือ ค่าการเลื่อนความถี่ดอปเปลอร์ (Doppler Frequency Offset) ที่เกิดขึ้นจากการเคลื่อนที่ของเป้าหมายในเส้นทางที่  $l$

ค่า CFR แต่ละตัวเป็นจำนวนเชิงซ้อน (Complex Number) ซึ่งสามารถแยกพิจารณาได้ทั้งในรูปแบบแอมพลิจูดและเฟส หรือส่วนจริงและส่วนจินตภาพ

$$H(k, m) = |H(k, m)| e^{j\angle H(k, m)} = I(k, m) + jQ(k, m)$$

โดยที่  $|H(k, m)|$  คือ แอมพลิจูด (Amplitude),  $\angle H(k, m)$  คือ เฟส (Phase),  $I(k, m)$  คือ ส่วนร่วมเฟส (In-phase Component) และ  $Q(k, m)$  คือ ส่วนตั้งฉากเฟส (Quadrature Component)

### 2.3.3 โครงสร้างข้อมูล CSI ในระบบ MIMO หลายสายอากาศ (MIMO-CSI Data Structure)

ในระบบที่มีการติดตั้งสายอากาศฝั่งส่งจำนวน  $N_{tx}$  ต้น และสายอากาศฝั่งรับจำนวน  $N_{rx}$  ต้น แต่ละคู่สายอากาศจะได้รับชุดข้อมูล CFR บน  $K$  สับแครี่เรียร์ ทำให้มิติของข้อมูลเชิงพื้นที่และความถี่รวมมีขนาด  $W = N_{tx} \times N_{rx} \times K$  สำหรับการนำข้อมูล CSI ไปประมวลผลด้วยปัญญาประดิษฐ์เพื่อการรู้จำตำแหน่งและการเคลื่อนไหว ข้อมูลส่วน  $I$  และ  $Q$  ของทุกคู่สายอากาศและสับแครี่เรียร์ ณ เวลา  $M$  ช่วงตัวอย่าง จะถูกนำมาจัดเรียงเป็นบล็อกข้อมูลเมทริกซ์ 2 มิติ

$$\mathbf{CSI}_{\text{sample}} \in \mathbb{R}^{W \times 2M}$$

โครงสร้างนี้ช่วยให้โมเดลสามารถเรียนรู้ทั้งความสัมพันธ์เชิงพื้นที่ระหว่างสายอากาศ (Spatial Correlation) รูปแบบการตอบสนองความถี่ (Frequency Selectivity) และพลวัตการเปลี่ยนแปลงตามเวลา (Temporal Evolution) ได้อย่างสมบูรณ์

### 2.3.4 ความสัมพันธ์ระหว่าง CFR และ CIR (Transformation between Frequency and Time Domains)

ผลตอบสนองความถี่ของช่องสัญญาณ (CFR:  $H(k, m)$ ) ในโดเมนความถี่ และผลตอบสนองเชิงอิมพัลส์ของช่องสัญญาณ (CIR:  $h(n, m)$ ) ในโดเมนเวลา-ความหน่วง มีความสัมพันธ์กันผ่านการแปลงฟูเรียร์ไม่ต่อเนื่อง (DFT / IDFT)

$$h(n, m) = \frac{1}{\sqrt{N}} \sum_{k=0}^{N-1} H(k, m) e^{j\frac{2\pi}{N}nk}, \quad n = 0, 1, \dots, N-1$$

การแปลง CFR ไปเป็น CIR ทำให้สามารถแยกแยะพลังงานและเวลาหน่วงของเส้นทางตรง (LOS) ออกจากเส้นทางสะท้อนหลายเส้นทาง (Multipath Components) ได้อย่างชัดเจน ซึ่งเป็นหัวใจสำคัญในการนำไปประยุกต์ใช้ในการหักล้างสัญญาณพื้นหลังสถิตและการระบุพิกัดตำแหน่ง 3 มิติ

## 2.4 ทฤษฎีการกรองสัญญาณความถี่ต่ำผ่านแบบบัตเตอร์เวิร์ธ (Butterworth Low-Pass Filtering in WiFi CSI Sensing)

### 2.4.1 องค์ประกอบของสัญญาณรบกวนในข้อมูล WiFi CSI (Noise Components in CSI Measurements)

ในการเก็บรวบรวมข้อมูลสถานะช่องสัญญาณ (CSI) ผ่านอุปกรณ์ WiFi สัญญาณที่ได้รับจริงจะประกอบด้วยสัญญาณจริงจากการแพร่กระจายของคลื่นวิทยุ รวมกับสัญญาณรบกวนจากการวัด (Measurement Noise)

$$\tilde{H}(k, t) = H(k, t) + n(k, t)$$

โดยที่  $n(k, t) \sim \mathcal{CN}(0, \sigma_n^2)$  คือ สัญญาณรบกวนเกาส์เซียนเชิงซ้อน (Complex Gaussian Measurement Noise) ซึ่งมีแหล่งกำเนิดหลัก 2 ส่วน

1) สัญญาณรบกวนความร้อน (Thermal Noise): สัญญาณรบกวนสุ่มที่กระจายตัวอยู่ในย่านความถี่สูง

2) สัญญาณรบกวนจากฮาร์ดแวร์ (Hardware-Induced Noise): ความผันผวนของวงจรขยายสัญญาณอัตโนมัติ (Automatic Gain Control: AGC) และการรบกวนของวงจรออสซิลเลเตอร์

เมื่อทำการแยกองค์ประกอบของช่องสัญญาณออกเป็น ส่วนสถิต และ ส่วนพลวัต  $H(k, t) = H_s(k) + H_d(k, t)$  โดยที่  $H_s(k)$  คือสัญญาณสะท้อนพื้นหลังสถิต และ  $H_d(k, t)$  คือสัญญาณที่เกิดจากการเคลื่อนไหวของมนุษย์ (Dynamic Human Motion Component) สัญญาณการเคลื่อนไหวของมนุษย์ เช่น การเดิน การเปลี่ยนอิริยาบถ หรือการล้ม จะมีการเปลี่ยนแปลงความถี่ดอปเปลอร์ (Doppler Frequency Shift) อยู่ในย่านความถี่ต่ำ (Low-frequency Bands โดยทั่วไปต่ำกว่า 50–100 Hz ขึ้นอยู่กับอัตราการสุ่มตัวอย่าง) ในขณะที่สัญญาณรบกวนทางความร้อนจะปรากฏในย่านความถี่สูง

### 2.4.2 หลักการทำงานและแบบจำลองทางคณิตศาสตร์ของตัวกรองบัตเตอร์เวิร์ธ (Butterworth Low-Pass Filter Model)

ตัวกรองความถี่ต่ำผ่านแบบบัตเตอร์เวิร์ธ (Butterworth Low-Pass Filter) มีคุณสมบัติเด่นคือเป็นตัวกรองสัญญาณดิจิทัลที่มีผลตอบสนองขนาดความถี่ราบเรียบที่สุดในแถบส่งผ่าน (Maximally Flat Passband Response) โดยไม่มีการกระเพื่อมของสัญญาณ (No Passband Ripple) จึงช่วยรักษา

รูปคลื่นและคุณลักษณะเฉพาะของการเคลื่อนไหวของมนุษย์ (Motion-Specific Features) ไม่ให้เกิดความผิดเพี้ยน ผลตอบสนองขนาดทางความถี่ (Frequency Magnitude Response) ของตัวกรองแบตเตอรี่เวอร์ธลำดับที่  $n$  แสดงได้ดังสมการ

$$|H_{bw}(f)|^2 = \frac{1}{1 + \left(\frac{f}{f_c}\right)^{2n}}$$

- 1)  $f$  คือ ความถี่ของสัญญาณ CSI
- 2)  $f_c$  คือ ความถี่ตัด (Cutoff Frequency) ซึ่งถูกปรับตั้งตามย่านความถี่ตอบสนองของการเคลื่อนไหวของมนุษย์ เพื่อตัดสัญญาณรบกวนความถี่สูงออก
- 3)  $n$  คือ ลำดับชั้นของตัวกรอง (Filter Order) ซึ่งกำหนดความชันในการลดทอนสัญญาณในแถบหยุด (Stopband Attenuation Rate)

#### 2.4.3 การบูรณาการตัวกรองในกระบวนการจัดสัญญาณรบกวน (Integrated Filtering Pipeline)

ในระบบตรวจจับและรู้จำกิจกรรมมนุษย์ด้วยคลื่น WiFi ตัวกรองแบตเตอรี่เวอร์ธความถี่ต่ำผ่านจะถูกนำมาใช้งานร่วมกับเทคนิคอื่น ๆ เป็นกระบวนการประมวลผลสัญญาณเบื้องต้นแบบผสมผสาน (Hybrid Filtering Pipeline)

- 1) การกำจัดสัญญาณรบกวนแบบอิมพัลส์ (Impulse Noise Removal): ใช้ตัวกรองแฮมเพิล (Hampel Filter) เพื่อขจัดจุดข้อมูลผิดปกติ (Outliers) ออกจากลำดับแอมพลิจูดของ CSI
- 2) การกรองความถี่ต่ำผ่าน (Low-Pass Filtering): ใช้ตัวกรองแบตเตอรี่เวอร์ธเพื่อกำจัดสัญญาณรบกวนความร้อนและสัญญาณรบกวนความถี่สูง โดยยังคงรักษารูปคลื่นการเคลื่อนไหวของมนุษย์ในย่านความถี่ต่ำไว้อย่างสมบูรณ์
- 3) การลดมิติข้อมูล (Dimensionality Reduction): ประยุกต์ใช้การวิเคราะห์องค์ประกอบหลัก (PCA) เพื่อคัดเลือกและบีบอัดสับแคร์เรียร์ที่มีนัยสำคัญต่อการเคลื่อนไหว ลดความซับซ้อนในการคำนวณ และเพิ่มอัตราส่วนสัญญาณต่อสัญญาณรบกวน (SNR)

#### 2.4.4 การประนีประนอมประสิทธิภาพและความทนทานต่อสภาพแวดล้อม (Performance Trade-offs)

การใช้ตัวกรองแบบดั้งเดิม เช่น ตัวกรองบัตเตอร์เวิร์ธ มีข้อได้เปรียบสำคัญคือ ความซับซ้อนในการคำนวณต่ำ (Low Computational Overhead) และมีความเสถียรสูง เหมาะสำหรับการประมวลผลแบบเรียลไทม์บนอุปกรณ์ประมวลผลขอบ (Edge Devices) เมื่อนำไปใช้งานร่วมกับตัวกรองสถิติและกระบวนการหักล้างสัญญาณพื้นหลัง จะช่วยเพิ่มค่า SNR ส่งผลให้ระบบตรวจจับการล้มและการเคลื่อนไหวสามารถสกัดแวกเตอร์คุณลักษณะที่มีความแม่นยำสูงก่อนป้อนเข้าสู่โมเดลปัญญาประดิษฐ์

### 2.5 ทฤษฎีอินเทอร์เน็ตของสรรพสิ่งสภาพปัญญาประดิษฐ์ (Artificial Intelligence of Things: AIoT)

#### 2.5.1 นิยามและแนวคิดพื้นฐานของ AIoT (Concept and Fundamentals of AIoT)

การหลอมรวมระหว่างเทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence: AI) และอินเทอร์เน็ตของสรรพสิ่ง (Internet of Things: IoT) หรือที่เรียกว่า Artificial Intelligence of Things (AIoT) เป็นวิวัฒนาการสำคัญของระบบดิจิทัลอัจฉริยะ โดย IoT ทำหน้าที่เป็นระบบประสาทสัมผัสในการเชื่อมต่ออุปกรณ์ เก็บข้อมูล และแลกเปลี่ยนข้อมูลจากสภาพแวดล้อมทางกายภาพ ในขณะที่ AI ทำหน้าที่เป็นสมองในการวิเคราะห์รูปแบบข้อมูล การเรียนรู้เชิงลึก และการตัดสินใจแบบอัตโนมัติ การผสานสองเทคโนโลยีเข้าด้วยกันช่วยยกระดับระบบจากการเก็บข้อมูลแบบตั้งรับ (Passive Data Collection) ไปสู่ระบบที่สามารถ รับรู้บริบท (Context-Aware Computing) สามารถประมวลผลตอบสนองได้แบบเรียลไทม์ (Real-Time Responsiveness) และสามารถปรับแต่งการทำงานได้ด้วยตนเอง (Self-Optimization) ซึ่งช่วยลดการพึ่งพามนุษย์และเพิ่มประสิทธิภาพการทำงานในสภาพแวดล้อมที่มีความเปลี่ยนแปลงตลอดเวลา

#### 2.5.2 สถาปัตยกรรมเชิงชั้นและแบบกระจายตัวของระบบ AIoT (Layered and Distributed AIoT Architectures)

ระบบ AIoT สมัยใหม่ถูกออกแบบภายใต้สถาปัตยกรรมแบบลำดับชั้นและการประมวลผลแบบกระจายตัว (Hybrid and Distributed Architectures) เพื่อแก้ไขปัญหาคอขวดด้านความหน่วง (Latency) แบนด์วิธ และความเป็นส่วนตัวของข้อมูล ซึ่งประกอบด้วยชั้นหลักดังนี้

1) ชั้นการรับรู้และการตรวจวัด (Perception / Sensing Layer) ประกอบด้วยอุปกรณ์ IoT ฮาร์ดแวร์ไมโครคอนโทรลเลอร์ และเซนเซอร์ตรวจวัดทางกายภาพ ทำหน้าที่เก็บข้อมูลดิบจากสิ่งแวดล้อม เช่น ข้อมูลคลื่นวิทยุ CSI หรือสัญญาณการเคลื่อนไหว

2) ชั้นเครือข่ายและการส่งผ่านข้อมูล (Network & Transmission Layer) ใช้โปรโตคอลการสื่อสารที่มีน้ำหนักเบาและประหยัดพลังงาน (เช่น MQTT, CoAP, AMQP) ร่วมกับเทคโนโลยีเครือข่ายไร้สายความเร็วสูง (เช่น WiFi, 5G/6G) เพื่อส่งผ่านข้อมูลแบบเรียลไทม์ด้วยความหน่วงต่ำและมีความน่าเชื่อถือสูง

3) ชั้นการประมวลผลอัจฉริยะแบบกระจายศูนย์ (Edge, Fog, and Cloud Intelligence Layer)

- การประมวลผลขอบ (Edge Computing / Edge AI) นำโมเดล AI ที่ผ่านการบีบอัดขนาด (Model Compression) ไปประมวลผลและอนุมานผล (Inference) บนอุปกรณ์ขอบหรือเกตเวย์โดยตรง ช่วยลดความหน่วงให้อยู่ในระดับมิลลิวินาที ประหยัดแบนด์วิดท์ และเพิ่มความปลอดภัยของข้อมูลเนื่องจากข้อมูลดิบไม่ต้องถูกส่งออกจากพื้นที่
- การประมวลผลบนคลาวด์และเซิร์ฟเวอร์ประสิทธิภาพสูง (Cloud / Server Computing) ทำหน้าที่เป็นศูนย์กลางในการฝึกสอนโมเดลขนาดใหญ่ (Model Training) การจัดเก็บข้อมูลประวัติระยะยาว และการวิเคราะห์เชิงลึกของระบบ

4) ชั้นการประยุกต์ใช้งานและการติดต่อผู้ใช้ (Application Layer) การนำผลลัพธ์จากการอนุมานของ AI ไปแสดงผลบนเว็บแอปพลิเคชัน แดชบอร์ดสำหรับผู้ดูแล และระบบส่งสัญญาณแจ้งเตือนเหตุการณ์ฉุกเฉินแบบอัตโนมัติ

2.5.3 การประยุกต์ใช้ AIoT ในระบบสุขภาพและการเฝ้าระวังผู้สูงอายุ (AIoT in Smart Healthcare and Safety Monitoring)

ในมิติด้านการแพทย์และการดูแลสุขภาพ (Smart Healthcare) AIoT มีบทบาทสำคัญในการพัฒนาระบบเฝ้าระวังผู้ป่วยและผู้สูงอายุระยะไกล (Remote Patient Monitoring) โดยระบบสามารถตรวจจับความผิดปกติ (Anomaly Detection) จากข้อมูลอนุกรมเวลา (Time-Series Data) ของการเคลื่อนไหวและสัญญาณชีพได้อย่างต่อเนื่อง จุดเด่นสำคัญของการประยุกต์ใช้ AIoT ในงานเฝ้าระวังคือ

1) การแจ้งเตือนอุบัติเหตุแบบทันท่วงที (Preemptive and Timely Alerts) อัลกอริทึมการเรียนรู้เชิงลึกสามารถจำแนกพฤติกรรมเสี่ยงหรืออุบัติเหตุการหกล้ม และส่งสัญญาณเตือนไปยังบุคลากรทางการแพทย์หรือผู้ดูแลได้ทันทีภายในช่วงเวลาสำคัญ (Golden Hour)

2) การรักษาความเป็นส่วนตัวของข้อมูลผู้ใช้งาน (Privacy Preservation) การผสมผสาน Edge AI ช่วยให้การวิเคราะห์พฤติกรรมเกิดขึ้นภายในระบบท้องถิ่น โดยไม่ต้องพึ่งพากล้องวิดีโอหรือส่งภาพเคลื่อนไหวที่ละเมิดความเป็นส่วนตัว ซึ่งสอดคล้องกับมาตรฐานความปลอดภัยของข้อมูลส่วนบุคคล (เช่น GDPR และ HIPAA)

#### 2.5.4 การจัดการวงจรชีวิตของโมเดล AI บนอุปกรณ์ IoT (AI Lifecycle Management in IoT)

เพื่อให้ระบบ AIoT สามารถทำงานได้อย่างมีประสิทธิภาพและต่อเนื่อง จำเป็นต้องมีกระบวนการจัดการวงจรชีวิตของโมเดล AI (AI Lifecycle Management) ซึ่งประกอบด้วย

1) การฝึกสอนและตรวจสอบความถูกต้องของโมเดล (Model Training and Validation) การพัฒนาและทดสอบประสิทธิภาพโมเดลบนชุดข้อมูลอนุกรมเวลา

2) การบีบอัดโมเดลเพื่อการติดตั้งใช้งาน (Model Compression and Deployment): การใช้เทคนิคการตัดแต่งกิ่งโครงข่าย (Pruning) การควอนไทเซชัน (Quantization) และการกลั่นกรององค์ความรู้ (Knowledge Distillation) เพื่อให้โมเดลมีขนาดเล็กและใช้พลังงานต่ำ เหมาะสมกับการทำงานบนฮาร์ดแวร์จำกัดทรัพยากร

3) การติดตามและปรับปรุงโมเดล (Model Monitoring and Governance): การตรวจวัดประสิทธิภาพเพื่อป้องกันปัญหาการเสื่อมถอยของโมเดล (Model Drift) เมื่อสภาพแวดล้อมทางกายภาพเปลี่ยนแปลงไป

## 2.6 งานวิจัยเกี่ยวข้อง

2.6.1 ระบบตรวจจับการหกล้มโดยใช้ค่าแอมพลิจูดของสัญญาณ WiFi CSI ด้วยเทคนิคสเกลโลแกรมที่ผ่านการขจัดสัญญาณรบกวน (AmFall: WiFi CSI Amplitude-Based Fall Detection Using Denoised Scalograms)

Yongkeun Kim และคณะ (2568) ระบุว่าระบบตรวจจับการหกล้มโดยใช้สัญญาณความถี่วิทยุได้รับความสนใจศึกษาอย่างต่อเนื่องในช่วงทศวรรษที่ผ่านมา เนื่องจากมีความเป็นส่วนตัวสูงและไม่จำเป็นต้องสวมใส่อุปกรณ์ โดยเฉพาะอย่างยิ่งระบบที่ใช้ค่าสถานะช่องสัญญาณ WiFi CSI (Channel State Information) ยังมีข้อได้เปรียบเพิ่มเติมคือไม่จำเป็นต้องใช้ฮาร์ดแวร์เฉพาะทาง

เนื่องจากอุปกรณ์ WiFi มีการใช้งานแพร่หลายอยู่แล้ว อย่างไรก็ตาม ผู้วิจัยชี้ให้เห็นว่าระบบที่ใช้ WiFi CSI มักประสบปัญหาประสิทธิภาพลดลงอย่างรุนแรงในสถานการณ์ข้ามโดเมน ซึ่งเป็นอุปสรรคสำคัญต่อการนำระบบไปใช้งานจริง เนื่องจากระบบตรวจจับการหกล้มที่มีประสิทธิภาพจำเป็นต้องสามารถทำงานได้ดีแม้อยู่ในสภาวะที่ไม่เอื้ออำนวย จากงานวิจัยดังกล่าวผู้วิจัยได้นำเสนอระบบตรวจจับการหกล้มโดยใช้ค่าแอมพลิจูดของสัญญาณ WiFi CSI ที่เรียกว่า AmFall ซึ่งสามารถแก้ปัญหาข้างต้นได้อย่างมีประสิทธิภาพเพื่อรับมือกับสถานการณ์ NLOS และ TTW ระบบ AmFall จะทำการคัดเลือก Subcarrier และองค์ประกอบหลักที่มีข้อมูลเป็นประโยชน์ นอกจากนี้เนื่องจากการแปลง CWT (Continuous Wavelet Transform) มีความเหมาะสมต่อการวิเคราะห์เชิงเวลาความถี่ของสัญญาณที่ไม่นิ่ง เช่นเดียวกับสัญญาณที่เกิดขึ้นระหว่างการหกล้ม ระบบ AmFall จึงสร้างภาพสเกลโลแกรม โดยประยุกต์ใช้ CWT กับสัญญาณ CSI ที่ผ่านกระบวนการจัดสัญญาณรบกวนด้วยอัลกอริทึมที่พัฒนาขึ้นใหม่ พร้อมทั้งสกัดข้อมูลความเร็วเพื่อใช้ในการแบ่งช่วงข้อมูล ก่อนนำภาพสเกลโลแกรมที่ผ่านการแบ่งช่วงแล้วไปป้อนเข้าสู่ตัวจำแนกประเภทที่ใช้เทคนิคการเรียนรู้เชิงลึก (Deep Learning) ทั้งนี้ ผู้วิจัยยังได้นำเสนอวิธีการเพิ่มจำนวนชุดข้อมูล ที่มีความเรียบง่ายแต่มีประสิทธิภาพ เพื่อสร้างภาพสเกลโลแกรมหลายภาพจากข้อมูล CSI เพียงชุดเดียว ระบบที่นำเสนอนี้ได้ถูกนำไปทดสอบบนอุปกรณ์ WiFi เชิงพาณิชย์ และให้ผลลัพธ์ความแม่นยำในการตรวจจับการหกล้มสูงถึง 95.28% - 99.67% ในสภาพแวดล้อมแบบ TTW และแบบข้ามโดเมน ซึ่งมีประสิทธิภาพเหนือกว่าวิธีการที่ใช้ WiFi เป็นฐานที่ทันสมัยที่สุดในปัจจุบัน

2.6.2 ระบบตรวจจับการหกล้มด้วยสัญญาณ WiFi CSI โดยใช้โพรไฟล์ความหนาแน่นความน่าจะเป็นของแอมพลิจูดเชิงพลวัต (DapFall: Dynamic Amplitude Probability Density Profile-Based Wi-Fi CSI Sensing for Fall Detection)

Zhuolong Chen และคณะ (2568) ระบุว่าระบบตรวจจับการหกล้มโดยใช้ค่าสภาวะช่องสัญญาณ WiFi CSI มีความอ่อนไหวสูงต่อการเปลี่ยนแปลงสภาพแวดล้อม โดยงานวิจัยที่ผ่านมามักจะเลยข้อมูล CSI Subcarrier Mutual Information ซึ่งเป็นข้อมูลที่มีความสำคัญในการแสดงลักษณะเฉพาะของแต่ละกิจกรรม และมีความทนทานต่อการเปลี่ยนแปลงสภาพแวดล้อม ด้วยเหตุนี้ ผู้วิจัยจึงได้นำเสนอระบบ DapFall ซึ่งเป็นระบบที่มีประสิทธิภาพในการใช้ข้อมูลอย่างคุ้มค่า และสามารถตรวจจับการหกล้มข้ามสภาพแวดล้อมได้โดยไม่ต้องฝึกโมเดลใหม่ แนวคิดหลักของ DapFall คือการแปลงค่าแอมพลิจูดของสัญญาณ CSI ให้อยู่ในรูปแบบ โพรไฟล์ความหนาแน่นความน่าจะเป็นของแอมพลิจูดเชิงพลวัต หรือ DAPD (Dynamic Amplitude Probability Density) ซึ่งเป็นการแสดงผลข้อมูลเชิงภาพแบบ 3 มิติที่เน้นย้ำคุณลักษณะเชิงพลวัตของสัญญาณอย่างชัดเจน นอกจากนี้ DAPD ยังคงรักษาข้อมูล SMI ไว้ได้

พร้อมทั้งลดทอนองค์ประกอบแบบคงที่ ของสัญญาณลงไปพร้อมกัน จากนั้น ผู้วิจัยได้ใช้เทคนิคการเพิ่มจำนวนข้อมูลเฉพาะทางเพื่อปรับเปลี่ยนคุณลักษณะความผันแปรของแอมพลิจูด อันเป็นการเพิ่มความหลากหลายของชุดข้อมูลการหกล้มให้มากยิ่งขึ้น ด้วยคุณสมบัติของ DAPD ทำให้ระบบสามารถใช้ประโยชน์จากองค์ความรู้ข้ามโดเมนได้อย่างมีประสิทธิภาพ โดยอาศัยโมเดลการเรียนรู้เชิงลึก R2+1D ที่ผ่านการฝึกล่วงหน้าจากงานที่ไม่มีความเกี่ยวข้องกันเลย ซึ่งช่วยเสริมความสามารถในการตรวจจับโดยไม่จำเป็นต้องใช้ข้อมูลจำนวนมาก ผลการทดลองแสดงให้เห็นว่า DapFall สามารถให้ค่าอัตราการตรวจพบจริง สูงถึง 94.3% และอัตราการแจ้งเตือนผิดพลาด เพียง 6.25% ในสภาพแวดล้อมดั้งเดิมแม้มีตัวอย่างข้อมูลฝึกสอนที่จำกัด อีกทั้งยังคงแสดงประสิทธิภาพที่มั่นคงในสภาพแวดล้อมอื่น ๆ โดยไม่จำเป็นต้องฝึกโมเดลใหม่แต่อย่างใด

### 2.6.3 ระบบตรวจจับการหกล้มโดยใช้สัญญาณสถานะช่องสัญญาณ WiFi ด้วยเทคนิคการเรียนรู้เชิงลึก (Deep Learning-Based Fall Detection Using WiFi Channel State Information)

Yi Chu และคณะ (2566) ระบุว่า การหกล้มเป็นหนึ่งในภัยคุกคามสำคัญต่อสุขภาพและความปลอดภัยของผู้สูงอายุมาโดยตลอด โดยเฉพาะอย่างยิ่งเมื่อผู้สูงอายุอาศัยอยู่ตามลำพัง แม้ว่าจะมีการพัฒนาระบบตรวจจับการหกล้มทั้งแบบสวมใส่ (Wearable) และแบบไม่สวมใส่ (Non-wearable) มาแล้วก็ตาม แต่ระบบตรวจจับการหกล้มที่ใช้ค่าสถานะช่องสัญญาณ WiFi CSI กลับได้รับความสนใจจากนักวิจัยเป็นอย่างมาก เนื่องจากมีคุณสมบัติไม่รบกวนผู้ใช้งานและมีต้นทุนต่ำ ทั้งนี้แม้จะมีระบบตรวจจับการหกล้มที่ใช้เทคนิค Machine Learning ร่วมกับ WiFi CSI อยู่แล้ว แต่ผู้วิจัยพบว่าระบบส่วนใหญ่ที่ฝึกด้วยชุดข้อมูลที่มีความครอบคลุมสูง กลับมีแนวโน้มให้ความแม่นยำค่อนข้างต่ำ เมื่อเปรียบเทียบกับระบบที่ฝึกด้วยชุดข้อมูลที่มีความครอบคลุมน้อยกว่า จากปัญหาดังกล่าว ผู้วิจัยจึงได้นำเสนอเทคนิคการตรวจจับการหกล้มแบบใหม่ด้วย Deep Learning โดยขั้นแรก ผู้วิจัยได้ทำการติดตั้งและประเมินเครื่องมือเก็บข้อมูล WiFi CSI ที่แตกต่างกันหลายชนิด เพื่อพิจารณาศักยภาพในการนำไปใช้กับงานตรวจจับการหกล้ม จากนั้นเพื่อพัฒนาเทคนิคการตรวจจับที่มีความแม่นยำสูง ผู้วิจัยได้สร้างชุดข้อมูลที่มีความครอบคลุมสูง ซึ่งประกอบด้วยตัวอย่างข้อมูล CSI มากกว่า 700 ตัวอย่าง ครอบคลุมทั้งประเภทของการหกล้มที่หลากหลาย และกิจกรรมประจำวันอื่นๆ โดยดำเนินการเก็บข้อมูลในสภาพแวดล้อมภายในอาคารที่แตกต่างกันถึง 4 แห่ง ทั้งบนเส้นทางสัญญาณหลักและนอกเส้นทางสัญญาณหลัก ด้วยชุดข้อมูลดังกล่าว ผู้วิจัยได้พัฒนาตัวจำแนกประเภทบนพื้นฐานของการเรียนรู้เชิงลึก โดยประยุกต์ใช้อัลกอริทึมการจำแนกภาพ ซึ่งจุดเด่นสำคัญของเทคนิคที่นำเสนอนี้คือ แตกต่างจากระบบตรวจจับการหกล้มอื่น ๆ ตรงที่ ต้องการเพียงขั้นตอนการลดอัตราสุ่มตัวอย่าง และการปรับรูปทรงข้อมูลในกระบวนการเตรียมข้อมูลเบื้องต้นเท่านั้น โดยไม่

จำเป็นต้องผ่านกระบวนการแปลงสัญญาณที่ซับซ้อน ผลการประเมินระบบตรวจจับการหลอมนำเสนอด้วยชุดข้อมูลที่สร้างขึ้น แสดงให้เห็นว่าระบบดังกล่าวมีประสิทธิภาพเหนือกว่าระบบที่มีอยู่เดิมอีก 2 ระบบ โดยสามารถให้ความแม่นยำ มากกว่า 96% สำหรับข้อมูล CSI ที่รวบรวมจากทั้ง 4 สภาพแวดล้อม และให้ความแม่นยำสูงถึง 99% สำหรับข้อมูล CSI ที่รวบรวมจากบางกลุ่มของสภาพแวดล้อม

2.6.4 ชุดข้อมูลมนุษย์ 4 มิติแบบหลายรูปแบบสัญญาณที่ไม่รบกวนผู้ใช้งาน สำหรับการรับรู้แบบไร้สายอเนกประสงค์ (MM-Fi: Multi-Modal Non-Intrusive 4D Human Dataset for Versatile Wireless Sensing)

Jianfei Yang และคณะ (2566) ระบุว่า การรับรู้มนุษย์เชิงพื้นที่ เวลาแบบ 4 มิติ มีบทบาทสำคัญอย่างยิ่งในการประยุกต์ใช้งานหลากหลายรูปแบบ เช่น ระบบอัตโนมัติภายในบ้าน และการจำลองอวตารในโลกเสมือน อย่างไรก็ตามแนวทางแก้ปัญหาที่มีอยู่เดิมซึ่งส่วนใหญ่พึ่งพากล้องและอุปกรณ์สวมใส่ต่างประสบปัญหาไม่ด้านใดก็ด้านหนึ่ง คือ ล่วงล้ำความเป็นส่วนตัว หรือ ไม่สะดวกต่อการใช้งาน ด้วยเหตุนี้ Wireless sensing จึงกลายเป็นทางเลือกที่มีศักยภาพในการแก้ปัญหาดังกล่าว โดยอาศัยสัญญาณจาก LiDAR mmWave radar และสัญญาณ WiFi เพื่อการตรวจจับมนุษย์แบบไม่ต้องพึ่งพาอุปกรณ์สวมใส่ จากงานวิจัยดังกล่าว ผู้วิจัยจึงได้นำเสนอ MM-Fi ซึ่งเป็นชุดข้อมูลมนุษย์ 4 มิติแบบหลายรูปแบบสัญญาณที่ไม่รบกวนผู้ใช้งานชุดแรก ครอบคลุมหมวดหมู่กิจกรรม 27 ประเภท ทั้งกิจกรรมประจำวันทั่วไปและ กิจกรรมเพื่อการฟื้นฟูสมรรถภาพทางการแพทย์ โดยมีวัตถุประสงค์เพื่อเชื่อมโยงช่องว่างระหว่างงานวิจัยด้านการรับรู้แบบไร้สายกับงานด้านการรับรู้มนุษย์ในระดับสูง ชุดข้อมูล MM-Fi ประกอบด้วยเฟรมข้อมูล ที่ผ่านการซิงโครไนซ์ มากกว่า 320,000 เฟรม จากรูปแบบสัญญาณทั้ง 5 ประเภท ซึ่งเก็บรวบรวมจากอาสาสมัครมนุษย์จำนวน 40 คน พร้อมทั้งมีการจัดเตรียมป้ายกำกับข้อมูล หลากหลายรูปแบบ เพื่อรองรับงานด้านการรับรู้ที่เป็นไปได้ในอนาคต เช่น Human pose estimation และ Action recognition นอกจากนี้ ผู้วิจัยยังได้ดำเนินการทดลองอย่างละเอียดเพื่อเปรียบเทียบศักยภาพในการตรวจจับ ของสัญญาณแต่ละประเภทหรือหลายประเภทร่วมกัน ในแง่มุมของงานที่หลากหลาย

2.6.5 การปรับปรุงระบบระบุตำแหน่งภายในอาคารด้วยเทคนิคการเรียนรู้ของเครื่อง (Improving Indoor Positioning System using Machine Learning Techniques)

นายธนภูมิ อังอำนวยศิริ และคณะ (2566) ได้นำเสนองานวิจัยที่มุ่งศึกษาการประมาณค่าพิกัดตำแหน่งของมนุษย์ภายในอาคาร โดยใช้เทคโนโลยี CSI พร้อมทั้งพัฒนาความแม่นยำของการประมาณค่าดังกล่าวผ่าน Machine Learning โดยผู้วิจัยระบุว่าเทคโนโลยี CSI สามารถให้ข้อมูลของสัญญาณ

ได้หลากหลายรูปแบบ ซึ่งเอื้อให้สามารถวิเคราะห์ข้อมูลได้อย่างละเอียด ในสภาพแวดล้อมของการทดลอง ผู้วิจัยได้พิจารณารูปแบบการวางตำแหน่งของตัวส่งสัญญาณ (Transmitter) และตัวรับสัญญาณ (Receiver) จำนวน 2 รูปแบบ เพื่อค้นหาการตรวจจับสัญญาณ CSI ที่มีประสิทธิภาพภายใต้การระบุตำแหน่งแบบไม่ต้องพึ่งพาอุปกรณ์ โดยรูปแบบแรกคืออุปกรณ์ทั้งสองตัวถูกวางไว้ที่มุมห้องในตำแหน่งตรงข้ามกัน ส่วนรูปแบบที่สองคือตัวส่งสัญญาณถูกวางไว้กึ่งกลางห้อง ในขณะที่ตัวรับสัญญาณถูกวางไว้ที่มุมห้อง ทั้งนี้ ผู้วิจัยได้พิจารณาเทคนิคการเรียนรู้ของเครื่อง 4 ประเภทสำหรับการประมาณค่าตำแหน่ง ได้แก่ ANN (Artificial Neural Network), KNN (K-Nearest Neighbor), Decision Tree และ Naive Bayes ในขั้นแรก ผู้วิจัยได้ตรวจสอบค่าสหสัมพันธ์ (Correlation) ของคุณลักษณะทั้งหมดในข้อมูลนำเข้า และค้นพบว่าคุณลักษณะเหล่านี้มีค่าสหสัมพันธ์ระหว่างกันในระดับต่ำ ผลการทดลองแสดงให้เห็นว่ารูปแบบการวางตำแหน่งที่สองของตัวส่งสัญญาณให้ความแม่นยำสูงกว่ารูปแบบแรก นอกจากนี้ ความแม่นยำในการระบุตำแหน่งของโมเดล ANN ในรูปแบบที่สองมีค่าสูงถึง 80.5% ซึ่งเป็นความแม่นยำสูงสุดเมื่อเทียบกับวิธีการอื่นทั้งหมด เนื่องจากโมเดล ANN มีความเหมาะสมอย่างยิ่งกับการประยุกต์ใช้งานกับข้อมูลที่มีค่าสหสัมพันธ์ต่ำ

#### 2.6.6 ระบบตรวจจับท่าทางอันตรายด้วย WiFi เชิงพาณิชย์สำหรับการเฝ้าระวังในห้องน้ำ (Danger-Pose Detection System Using Commodity Wi-Fi for Bathroom Monitoring)

Zizheng Zhang และคณะ (2562) ระบุว่าห้องน้ำเป็นพื้นที่ที่มีความน่าจะเป็นในการเกิดอุบัติเหตุสูงกว่าห้องอื่น ๆ ภายในบ้าน เนื่องจากพื้นลื่นและการเปลี่ยนแปลงของอุณหภูมิ อย่างไรก็ตาม ด้วยเหตุผลด้านความเป็นส่วนตัวสูงและความชื้นภายในห้องน้ำ ทำให้เกิดความยากลำบากในการเฝ้าระวังภายในห้องน้ำด้วยวิธีการด้านสุขภาพแบบดั้งเดิมที่อาศัยกล้องและเซนเซอร์สวมใส่ ด้วยเหตุนี้ ผู้วิจัยจึงได้นำเสนอระบบตรวจจับท่าทางอันตราย (Danger-pose detection system) โดยใช้อุปกรณ์ WiFi เชิงพาณิชย์ (Commodity WiFi devices) ซึ่งสามารถนำไปประยุกต์ใช้กับการเฝ้าระวังในห้องน้ำได้ โดยยังคงรักษาความเป็นส่วนตัวของผู้ใช้งานไว้ ผู้วิจัยชี้ให้เห็นว่าวิธีการตรวจจับด้วย Machine Learning มักต้องอาศัยข้อมูลที่เก็บรวบรวมจากสถานการณ์เป้าหมายโดยตรง ซึ่งเป็นเรื่องยากอย่างยิ่งสำหรับการตรวจจับสถานการณ์อันตราย เนื่องจากไม่สามารถจำลองหรือเก็บข้อมูลจริงในสภาวะอันตรายได้อย่างปลอดภัย ด้วยเหตุนี้ ผู้วิจัยจึงได้ประยุกต์ใช้วิธีการตรวจจับความผิดปกติ บนพื้นฐานของการเรียนรู้ของเครื่อง ซึ่งต้องการข้อมูลในสภาวะผิดปกติเพียงจำนวนน้อย อันเป็นการลดปริมาณข้อมูลฝึกสอนที่ต้องเก็บรวบรวมจากสถานการณ์อันตรายให้เหลือน้อยที่สุด ในด้านกระบวนการทางเทคนิค ผู้วิจัยเริ่มต้นด้วยการสกัดค่าแอมพลิจูดและการเลื่อนเฟส (Phase shift) จากค่าสภาวะช่องสัญญาณ WiFi CSI เพื่อสกัดองค์ประกอบ

ความถี่ต่ำที่มีความสัมพันธ์กับกิจกรรมของมนุษย์ จากนั้นจึงสกัดคุณลักษณะแบบคงที่ และคุณลักษณะเชิงพลวัตแยกจากกัน จากการเปลี่ยนแปลงของ CSI ตามเวลาสุดท้าย คุณลักษณะทั้งสองประเภทจะถูกป้อนเข้าสู่ตัวจำแนกประเภท One-Class Support Vector Machine: SVM ซึ่งทำหน้าที่เป็นวิธีการตรวจจับความผิดปกติ เพื่อจำแนกว่าผู้ใช้งานอยู่ในสถานะใดสถานะหนึ่งจาก 3 สถานะ ได้แก่ ไม่อยู่ในอ่างอาบน้ำ อาบน้ำอย่างปลอดภัย หรืออยู่ในสภาวะอันตราย ผู้วิจัยได้ดำเนินการทดลองเชิงประจักษ์และแสดงให้เห็นว่าระบบตรวจจับท่าทางอันตรายที่นำเสนอนี้สามารถให้ประสิทธิภาพการตรวจจับในระดับสูงแม้จะอยู่ภายใต้สถานการณ์ที่ไม่มีเส้นสายตาตรงระหว่างอุปกรณ์และเป้าหมาย