

บทที่ 2

ทฤษฎีและงานวิจัยเกี่ยวข้อง

บทนี้นำเสนอทฤษฎีและงานวิจัยที่เกี่ยวข้องกับ ระบบตรวจจับการล้มอัจฉริยะด้วยปัญญาประดิษฐ์ จากคลื่นไวไฟ โดยคณะผู้จัดทำได้ศึกษาค้นคว้างานวิจัยที่เกี่ยวข้อง และทฤษฎีที่เกี่ยวข้องที่สอดคล้องกัน เพื่อนำมาเป็นแนวทางในการพัฒนาระบบให้มีประสิทธิภาพ โดยเนื้อหาทั้งหมดจะเป็นพื้นฐานสำคัญในการออกแบบและพัฒนาระบบตรวจจับการหกล้มที่นำเสนอในบทถัดไป

2.1 งานวิจัยเกี่ยวข้อง

2.1.1 ระบบตรวจจับการหกล้มโดยใช้ค่าแอมพลิจูดของสัญญาณ WiFi CSI ด้วยเทคนิคสเกลโลแกรม ที่ผ่านการขจัดสัญญาณรบกวน (AmFall: WiFi CSI Amplitude-Based Fall Detection Using Denoised Scalograms)

Yongkeun Kim และคณะ (2568) ระบุว่าระบบตรวจจับการหกล้มโดยใช้สัญญาณความถี่วิทยุได้รับความสนใจศึกษาอย่างต่อเนื่องในช่วงทศวรรษที่ผ่านมา เนื่องจากมีความเป็นส่วนตัวสูงและไม่จำเป็นต้องสวมใส่อุปกรณ์ โดยเฉพาะอย่างยิ่งระบบที่ใช้ค่าสถานะช่องสัญญาณ WiFi CSI (Channel State Information) ยังมีข้อได้เปรียบเพิ่มเติมคือไม่จำเป็นต้องใช้ฮาร์ดแวร์เฉพาะทาง เนื่องจากอุปกรณ์ WiFi มีการใช้งานแพร่หลายอยู่แล้ว อย่างไรก็ตาม ผู้วิจัยชี้ให้เห็นว่าระบบที่ใช้ WiFi CSI มักประสบปัญหาประสิทธิภาพลดลงอย่างรุนแรงในสถานการณ์ข้ามโดเมน ซึ่งเป็นอุปสรรคสำคัญต่อการนำระบบไปใช้งานจริง เนื่องจากระบบตรวจจับการหกล้มที่มีประสิทธิภาพจำเป็นต้องสามารถทำงานได้ดีแม้อยู่ในสถานะที่ไม่เอื้ออำนวย จากงานวิจัยดังกล่าวผู้วิจัยได้นำเสนอระบบตรวจจับการหกล้มโดยใช้ค่าแอมพลิจูดของสัญญาณ WiFi CSI ที่เรียกว่า AmFall ซึ่งสามารถแก้ปัญหาข้างต้นได้อย่างมีประสิทธิภาพเพื่อรับมือกับสถานการณ์ NLOS และ TTW ระบบ AmFall จะทำการคัดเลือก Subcarrier และองค์ประกอบหลักที่มีข้อมูลเป็นประโยชน์ นอกจากนี้เนื่องจากการแปลง CWT มีความเหมาะสมต่อการวิเคราะห์เชิงเวลาความถี่ของสัญญาณที่ไม่นิ่ง เช่นเดียวกับสัญญาณที่เกิดขึ้นระหว่างการหกล้ม ระบบ AmFall จึงสร้างภาพสเกลโลแกรม โดยประยุกต์ใช้ CWT กับสัญญาณ CSI ที่ผ่านกระบวนการขจัดสัญญาณรบกวนด้วยอัลกอริทึมที่พัฒนาขึ้นใหม่ พร้อมทั้งสกัดข้อมูลความเร็ว เพื่อใช้ในการแบ่งช่วงข้อมูลก่อนนำภาพสเกลโลแกรมที่ผ่านการแบ่งช่วงแล้วไปป้อนเข้าสู่ตัวจำแนกประเภทที่ใช้เทคนิคการเรียนรู้เชิงลึก ทั้งนี้ ผู้วิจัยยังได้นำเสนอวิธีการเพิ่มจำนวนชุดข้อมูล ที่มีความเรียบง่ายแต่มีประสิทธิภาพ

เพื่อสร้างภาพสเกโลแกรมหลายภาพจากข้อมูล CSI เพียงชุดเดียว ระบบที่นำเสนอนี้ได้ถูกนำไปทดสอบบนอุปกรณ์ WiFi เชิงพาณิชย์ และให้ผลลัพธ์ความแม่นยำในการตรวจจับการหกล้มสูงถึง 95.28% - 99.67% ในสภาพแวดล้อมแบบ TTW และแบบข้ามโดเมน ซึ่งมีประสิทธิภาพเหนือกว่าวิธีการที่ใช้ WiFi เป็นฐานที่ทันสมัยที่สุดในปัจจุบัน

2.1.2 ระบบตรวจจับการหกล้มด้วยสัญญาณ WiFi CSI โดยใช้โพรไฟล์ความหนาแน่นความน่าจะเป็นของแอมพลิจูดเชิงพลวัต (DapFall: Dynamic Amplitude Probability Density Profile-Based Wi-Fi CSI Sensing for Fall Detection)

Zhuolong Chen และคณะ (2568) ระบุว่าระบบตรวจจับการหกล้มโดยใช้ค่าสถานะช่องสัญญาณ WiFi CSI มีความอ่อนไหวสูงต่อการเปลี่ยนแปลงสภาพแวดล้อม โดยงานวิจัยที่ผ่านมามักจะเลยข้อมูล CSI Subcarrier Mutual Information ซึ่งเป็นข้อมูลที่มีความสำคัญในการแสดงลักษณะเฉพาะของแต่ละกิจกรรม และมีความทนทานต่อการเปลี่ยนแปลงสภาพแวดล้อม ด้วยเหตุนี้ผู้วิจัยจึงได้นำเสนอระบบ DapFall ซึ่งเป็นระบบที่มีประสิทธิภาพในการใช้ข้อมูลอย่างคุ้มค่า และสามารถตรวจจับการหกล้มข้ามสภาพแวดล้อมได้โดยไม่ต้องฝึกโมเดลใหม่ แนวคิดหลักของ DapFall คือการแปลงค่าแอมพลิจูดของสัญญาณ CSI ให้อยู่ในรูปแบบ โพรไฟล์ความหนาแน่นความน่าจะเป็นของแอมพลิจูดเชิงพลวัต หรือ DAPD ซึ่งยังคงรักษาข้อมูล SMI ไว้ได้ พร้อมทั้งลดทอนองค์ประกอบแบบคงที่ของสัญญาณลงไปพร้อมกัน จากนั้น ผู้วิจัยได้ใช้เทคนิคการเพิ่มจำนวนข้อมูลเฉพาะทางเพื่อปรับเปลี่ยนคุณลักษณะความผันแปรของแอมพลิจูด อันเป็นการเพิ่มความหลากหลายของชุดข้อมูลการหกล้มให้มากยิ่งขึ้น ด้วยคุณสมบัติของ DAPD ทำให้ระบบสามารถใช้ประโยชน์จากองค์ความรู้ข้ามโดเมนได้อย่างมีประสิทธิภาพ โดยอาศัยโมเดลการเรียนรู้เชิงลึกที่ผ่านการฝึกล่วงหน้าจากงานที่ไม่มีความเกี่ยวข้องกันเลย ซึ่งช่วยเสริมความสามารถในการตรวจจับโดยไม่ต้องใช้ข้อมูลจำนวนมาก ผลการทดลองแสดงให้เห็นว่า DapFall สามารถให้ค่าอัตราการตรวจพบจริง สูงถึง 94.3% และอัตราการแจ้งเตือนผิดพลาดเพียง 6.25% ในสภาพแวดล้อมดั้งเดิมแม้มีตัวอย่างข้อมูลฝึกสอนที่จำกัด อีกทั้งยังคงแสดงประสิทธิภาพที่มั่นคงในสภาพแวดล้อมอื่น ๆ โดยไม่จำเป็นต้องฝึกโมเดลใหม่แต่อย่างใด

2.1.3 ระบบตรวจจับการหกล้มโดยใช้สัญญาณสถานะช่องสัญญาณ WiFi ด้วยเทคนิคการเรียนรู้เชิงลึก (Deep Learning-Based Fall Detection Using WiFi Channel State Information)

Yi Chu และคณะ (2566) ระบุว่า การหกล้มเป็นหนึ่งในภัยคุกคามสำคัญต่อสุขภาพและความเป็นอยู่ที่ดีของผู้สูงอายุมาโดยตลอด โดยเฉพาะอย่างยิ่งเมื่อผู้สูงอายุอาศัยอยู่ตามลำพัง แม้ว่าจะมีการพัฒนาระบบตรวจจับการหกล้มทั้งแบบสวมใส่และแบบไม่สวมใส่มาแล้วก็ตาม แต่ระบบตรวจจับการหกล้มที่ใช้ค่าสถานะช่องสัญญาณ WiFi CSI กลับได้รับความสนใจจากนักวิจัยเป็นอย่างมาก เนื่องจากมีคุณสมบัติไม่รบกวนผู้ใช้งานและมีต้นทุนต่ำ ทั้งนี้แม้จะมีระบบตรวจจับการหกล้มที่ใช้เทคนิค Machine Learning ร่วมกับ WiFi CSI อยู่แล้ว แต่ผู้วิจัยพบว่าระบบส่วนใหญ่ที่ฝึกด้วยชุดข้อมูลที่มีความครอบคลุมสูง กลับมีแนวโน้มให้ความแม่นยำค่อนข้างต่ำ เมื่อเปรียบเทียบกับระบบที่ฝึกด้วยชุดข้อมูลที่มีความครอบคลุมน้อยกว่า จากปัญหาดังกล่าว ผู้วิจัยจึงได้นำเสนอเทคนิคการตรวจจับการหกล้มแบบใหม่ด้วย Deep Learning โดยขั้นแรก ผู้วิจัยได้ทำการติดตั้งและประเมินเครื่องมือเก็บข้อมูล WiFi CSI ที่แตกต่างกันหลายชนิด เพื่อพิจารณาศักยภาพในการนำไปใช้กับงานตรวจจับการหกล้ม จากนั้น เพื่อพัฒนาเทคนิคการตรวจจับที่มีความแม่นยำสูง ผู้วิจัยได้สร้างชุดข้อมูลที่มีความครอบคลุมสูง ซึ่งประกอบด้วยตัวอย่างข้อมูล CSI มากกว่า 700 ตัวอย่าง ครอบคลุมทั้งประเภทของการหกล้มที่หลากหลายและกิจกรรมประจำวันอื่นๆ โดยดำเนินการเก็บข้อมูลในสภาพแวดล้อมภายในอาคารที่แตกต่างกันถึง 4 แห่ง ทั้งบนเส้นทางสัญญาณหลักและนอกเส้นทางสัญญาณหลัก ด้วยชุดข้อมูลดังกล่าว ผู้วิจัยได้พัฒนาตัวจำแนกประเภทบนพื้นฐานของการเรียนรู้เชิงลึก โดยประยุกต์ใช้อัลกอริทึมการจำแนกภาพ ซึ่งจุดเด่นสำคัญของเทคนิคที่นำเสนอนี้คือ แตกต่างจากระบบตรวจจับการหกล้มอื่น ๆ ตรงที่ ต้องการเพียงขั้นตอนการลดอัตราสุ่มตัวอย่าง และการปรับรูปทรงข้อมูลในกระบวนการเตรียมข้อมูลเบื้องต้นเท่านั้น โดยไม่จำเป็นต้องผ่านกระบวนการแปลงสัญญาณที่ซับซ้อน ผลการประเมินระบบตรวจจับการหกล้มที่นำเสนอด้วยชุดข้อมูลที่สร้างขึ้น แสดงให้เห็นว่าระบบดังกล่าวมีประสิทธิภาพเหนือกว่าระบบที่มีอยู่เดิมอีก 2 ระบบ โดยสามารถให้ความแม่นยำ มากกว่า 96% สำหรับข้อมูล CSI ที่รวบรวมจากทั้ง 4 สภาพแวดล้อม และให้ความแม่นยำสูงถึง 99% สำหรับข้อมูล CSI ที่รวบรวมจากบางกลุ่มของสภาพแวดล้อม

2.1.4 ชุดข้อมูลมนุษย์ 4 มิติแบบหลายรูปแบบสัญญาณที่ไม่รบกวนผู้ใช้งาน สำหรับการรับรู้แบบไร้สายอเนกประสงค์ (MM-Fi: Multi-Modal Non-Intrusive 4D Human Dataset for Versatile Wireless Sensing)

Jianfei Yang และคณะ (2566) ระบุว่า การรับรู้มนุษย์เชิงพื้นที่ เวลาแบบ 4 มิติ มีบทบาทสำคัญอย่างยิ่งในการประยุกต์ใช้งานหลากหลายรูปแบบ เช่น ระบบอัตโนมัติภายในบ้าน และการจำลองอวตารในโลกเสมือน อย่างไรก็ตามแนวทางแก้ปัญหาที่มีอยู่เดิมซึ่งส่วนใหญ่พึ่งพาล้องและอุปกรณ์สวมใส่ต่างประสบปัญหาไม่ด้านใดก็ด้านหนึ่ง คือ ล่วงล้ำความเป็นส่วนตัว หรือ ไม่สะดวกต่อการใช้งาน ด้วยเหตุนี้ Wireless sensing จึงกลายเป็นทางเลือกที่มีศักยภาพในการแก้ปัญหาดังกล่าว โดยอาศัยสัญญาณจาก LiDAR mmWave radar และสัญญาณ WiFi เพื่อการตรวจจับมนุษย์แบบไม่ต้องพึ่งพาอุปกรณ์สวมใส่ จากงานวิจัยดังกล่าว ผู้วิจัยจึงได้นำเสนอ MM-Fi ซึ่งเป็นชุดข้อมูลมนุษย์ 4 มิติแบบหลายรูปแบบสัญญาณที่ไม่รบกวนผู้ใช้งานชุดแรก ครอบคลุมหมวดหมู่กิจกรรม 27 ประเภท ทั้งกิจกรรมประจำวันทั่วไปและ กิจกรรมเพื่อการฟื้นฟูสมรรถภาพทางการแพทย์ โดยมีวัตถุประสงค์เพื่อเชื่อมโยงช่องว่างระหว่างงานวิจัยด้านการรับรู้แบบไร้สายกับงานด้านการรับรู้มนุษย์ในระดับสูง ชุดข้อมูล MM-Fi ประกอบด้วยเฟรมข้อมูล ที่ผ่านการชิงโครไนซ์ มากกว่า 320,000 เฟรม จากรูปแบบสัญญาณทั้ง 5 ประเภท ซึ่งเก็บรวบรวมจากอาสาสมัครมนุษย์จำนวน 40 คน พร้อมทั้งมีการจัดเตรียมป้ายกำกับข้อมูล หลากหลายรูปแบบ เพื่อรองรับงานด้านการรับรู้ที่เป็นไปได้ในอนาคต เช่น Human pose estimation และ Action recognition นอกจากนี้ ผู้วิจัยยังได้ดำเนินการทดลองอย่างละเอียดเพื่อเปรียบเทียบศักยภาพในการตรวจจับ ของสัญญาณแต่ละประเภทหรือหลายประเภทร่วมกัน ในแง่มุมของงานที่หลากหลาย

2.1.5 การปรับปรุงระบบระบุตำแหน่งภายในอาคารด้วยเทคนิคการเรียนรู้ของเครื่อง (Improving Indoor Positioning System using Machine Learning Techniques)

นายธนภูมิ อังอำนวยศิริ และคณะ (2566) ได้นำเสนองานวิจัยที่มุ่งศึกษาการประมาณค่าพิกัดตำแหน่งของมนุษย์ภายในอาคาร โดยใช้เทคโนโลยี CSI พร้อมทั้งพัฒนาความแม่นยำของการประมาณค่าดังกล่าวผ่าน Machine Learning โดยผู้วิจัยระบุว่าเทคโนโลยี CSI สามารถให้ข้อมูลช่องสัญญาณ ได้หลากหลายรูปแบบ ซึ่งเอื้อให้สามารถวิเคราะห์ข้อมูลได้อย่างละเอียด ในสภาพแวดล้อมของการทดลอง ผู้วิจัยได้พิจารณารูปแบบการวางตำแหน่งของตัวส่งสัญญาณ (Transmitter) และตัวรับสัญญาณ (Receiver) จำนวน 2 รูปแบบ เพื่อค้นหาการตรวจจับสัญญาณ CSI ที่มีประสิทธิภาพภายใต้การระบุตำแหน่งแบบไม่ต้องพึ่งพาอุปกรณ์ โดยรูปแบบแรกคืออุปกรณ์ทั้งสองตัวถูกวางไว้ที่มุมห้องในตำแหน่งตรงข้ามกัน ส่วนรูปแบบที่สองคือตัวส่งสัญญาณถูกวางไว้กึ่งกลางห้อง ในขณะที่ตัวรับสัญญาณถูกวางไว้ที่มุมห้อง ทั้งนี้ ผู้วิจัยได้พิจารณาเทคนิคการเรียนรู้ของเครื่อง 4 ประเภทสำหรับการประมาณค่าตำแหน่ง ได้แก่ ANN (Artificial Neural Network), KNN (K-Nearest Neighbor), Decision Tree และ Naive Bayes ในขั้นแรก ผู้วิจัยได้ตรวจสอบค่าสหสัมพันธ์ (Correlation) ของคุณลักษณะทั้งหมดในข้อมูลนำเข้า

และค้นพบว่าคุณลักษณะเหล่านี้มีค่าสหสัมพันธ์ระหว่างกันในระดับต่ำ ผลการทดลองแสดงให้เห็นว่ารูปแบบการวางตำแหน่งที่สองของตัวส่งสัญญาณให้ความแม่นยำสูงกว่ารูปแบบแรก นอกจากนี้ ความแม่นยำในการระบุตำแหน่งของโมเดล ANN ในรูปแบบที่สองมีค่าสูงถึง 80.5% ซึ่งเป็นความแม่นยำสูงสุดเมื่อเทียบกับวิธีการอื่นทั้งหมด เนื่องจากโมเดล ANN มีความเหมาะสมอย่างยิ่งกับการประยุกต์ใช้งานกับข้อมูลที่มีค่าสหสัมพันธ์ต่ำ

2.1.6 ระบบตรวจจับท่าทางอันตรายด้วย WiFi เชิงพาณิชย์สำหรับการเฝ้าระวังในห้องน้ำ (Danger-Pose Detection System Using Commodity Wi-Fi for Bathroom Monitoring)

Zizheng Zhang และคณะ (2562) ระบุว่าห้องน้ำเป็นพื้นที่ที่มีความน่าจะเป็นในการเกิดอุบัติเหตุสูงกว่าห้องอื่น ๆ ภายในบ้าน เนื่องจากพื้นลื่นและการเปลี่ยนแปลงของอุณหภูมิ อย่างไรก็ตาม ด้วยเหตุผลด้านความเป็นส่วนตัวและความชื้นภายในห้องน้ำ ทำให้เกิดความยากลำบากในการเฝ้าระวังภายในห้องน้ำด้วยวิธีการด้านสุขภาพแบบดั้งเดิมที่อาศัยกล้องและเซนเซอร์สวมใส่ ด้วยเหตุนี้ ผู้วิจัยจึงได้นำเสนอระบบตรวจจับท่าทางอันตราย (Danger-pose detection system) โดยใช้อุปกรณ์ WiFi เชิงพาณิชย์ (Commodity WiFi devices) ซึ่งสามารถนำไปประยุกต์ใช้กับการเฝ้าระวังในห้องน้ำได้ โดยยังคงรักษาความเป็นส่วนตัวของผู้ใช้งานไว้ ผู้วิจัยชี้ให้เห็นว่าวิธีการตรวจจับด้วย Machine Learning มักต้องอาศัยข้อมูลที่เก็บรวบรวมจากสถานการณ์เป้าหมายโดยตรง ซึ่งเป็นเรื่องยากอย่างยิ่งสำหรับการตรวจจับสถานการณ์อันตราย เนื่องจากไม่สามารถจำลองหรือเก็บข้อมูลจริงในสถานะอันตรายได้อย่างปลอดภัย ด้วยเหตุนี้ ผู้วิจัยจึงได้ประยุกต์ใช้วิธีการตรวจจับความผิดปกติ บนพื้นฐานของการเรียนรู้ของเครื่อง ซึ่งต้องการข้อมูลในสถานะผิดปกติเพียงจำนวนน้อย อันเป็นการลดปริมาณข้อมูลฝึกสอนที่ต้องเก็บรวบรวมจากสถานการณ์อันตรายให้เหลือน้อยที่สุด ในด้านกระบวนการทางเทคนิค ผู้วิจัยเริ่มต้นด้วยการสกัดค่าแอมพลิจูดและการเลื่อนเฟส (Phase shift) จากค่าสถานะช่องสัญญาณ WiFi CSI เพื่อสกัดองค์ประกอบความถี่ต่ำที่มีความสัมพันธ์กับกิจกรรมของมนุษย์ จากนั้นจึงสกัดคุณลักษณะแบบคงที่ และคุณลักษณะเชิงพลวัตแยกจากกัน จากการเปลี่ยนแปลงของ CSI ตามเวลาสุดท้าย คุณลักษณะทั้งสองประเภทจะถูกป้อนเข้าสู่ตัวจำแนกประเภท One-Class Support Vector Machine: SVM ซึ่งทำหน้าที่เป็นวิธีการตรวจจับความผิดปกติ เพื่อจำแนกว่าผู้ใช้งานอยู่ในสถานะใดสถานะหนึ่งจาก 3 สถานะ ได้แก่ ไม่อยู่ในอ่างอาบน้ำ อาบน้ำอย่างปลอดภัย หรืออยู่ในสถานะอันตราย ผู้วิจัยได้ดำเนินการทดลองเชิงประจักษ์และแสดงให้เห็นว่าระบบตรวจจับท่าทางอันตรายที่นำเสนอสามารถให้ประสิทธิภาพการตรวจจับในระดับสูง แม้จะอยู่ภายใต้สถานการณ์ที่ไม่มีเส้นสายตาตรงระหว่างอุปกรณ์และเป้าหมาย

2.2 ข้อมูลสถานะช่องสัญญาณวิทยุและผลตอบสนองความถี่ของช่องสัญญาณ (Channel State Information & Channel Frequency Response)

2.2.1 นิยามและแนวคิดพื้นฐานของข้อมูลสถานะช่องสัญญาณ (Definition and Fundamentals of CSI)

ในระบบเครือข่ายไร้สายมาตรฐาน IEEE 802.11 ข้อมูลสถานะช่องสัญญาณ (Channel State Information, CSI) เป็นข้อมูลระดับชั้นกายภาพ (Physical Layer, PHY) ที่บ่งบอกถึงคุณสมบัติการแพร่กระจายของคลื่นวิทยุระหว่างสายอากาศตัวส่ง Tx และสายอากาศตัวรับ Rx ซึ่งมีความละเอียดและเสถียรมากกว่าค่าบ่งชี้ความแรงของสัญญาณที่ได้รับ (Received Signal Strength Indicator, RSSI) ในระดับชั้น MAC เนื่องจาก RSSI เป็นเพียงค่าสเกลารวมที่สูญเสียมิติของความถี่และเฟส ในระบบ WiFi ที่ใช้เทคโนโลยี (Orthogonal Frequency Division Multiplexing, OFDM) สัญญาณจะถูกแบ่งออกเป็นหลายพาหะย่อย (Subcarriers) ข้อมูล CSI ที่ตัวรับสกัดได้จากลำดับฝึกฝน (Pilot/Training Sequences) ในแต่ละแพ็กเก็ต คือค่า ผลตอบสนองความถี่ของช่องสัญญาณ (Channel Frequency Response, CFR) ซึ่งสะท้อนผลกระทบของการลดทอน (Attenuation) การเลื่อนเฟส (Phase Shift) และการแพร่กระจายหลายเส้นทาง (Multipath Propagation) ในแต่ละพาหะย่อยอย่างละเอียด

2.2.2 แบบจำลองทางคณิตศาสตร์ของผลตอบสนองความถี่ของช่องสัญญาณ (Mathematical Model of CFR)

เมื่อคลื่นวิทยุเดินทางจากตัวส่งไปยังตัวรับ คลื่นจะเดินทางผ่านเส้นทางการแพร่กระจายหลายเส้นทาง (Multipath Paths) จำนวน L เส้นทาง ซึ่งประกอบด้วยเส้นทางแนวสายตาตรง (Line-of-Sight, LOS) และเส้นทางสะท้อนจากวัตถุต่างๆ ในสภาพแวดล้อมรวมถึงร่างกายมนุษย์ ค่า CFR ณ สับแคร์เรียร์ลำดับที่ k ที่เวลาการสุ่มตัวอย่าง $t(m)$ สามารถจำลองเชิงคณิตศาสตร์ได้ดังสมการ

$$H(k, m) = \sum_{l=0}^{L-1} \alpha_l(k, m) e^{-j2\pi f(k)\tau_l} \cdot e^{j2\pi t(m)\nu_l} \quad (2.1)$$

- 1) $k \in \{0, 1, \dots, K-1\}$ คือ ดัชนีของสับแคร้เรียร์ โดยมีจำนวนสับแคร้เรียร์ทั้งหมด K ชุด
- 2) $f(k)$ คือ ความถี่ของสับแคร้เรียร์ลำดับที่ k
- 3) $t(m)$ คือ เวลา ณ ขณะที่รับแพ็กเก็ตลำดับที่ m
- 4) $\alpha_l(k, m)$ คือ สัมประสิทธิ์การลดทอนของสัญญาณเชิงซ้อนในเส้นทางที่ l
- 5) τ_l คือ เวลาหน่วงในการแพร่กระจายสัญญาณ (Propagation Delay) ของเส้นทางที่ l
- 6) ν_l คือ ค่าการเลื่อนความถี่ดอปเปลอร์ (Doppler Frequency Offset) ที่เกิดขึ้นจากการเคลื่อนที่ของเป้าหมายในเส้นทางที่ l

ค่า CFR แต่ละตัวเป็นจำนวนเชิงซ้อน (Complex Number) ซึ่งสามารถแยกพิจารณาได้ทั้งในรูปแบบแอมพลิจูดและเฟส หรือส่วนจริงและส่วนจินตภาพ

$$H(k, m) = |H(k, m)|e^{j\angle H(k, m)} = I(k, m) + jQ(k, m) \quad (2.2)$$

โดยที่ $|H(k, m)|$ คือ แอมพลิจูด (Amplitude) $\angle H(k, m)$ คือ เฟส (Phase), $I(k, m)$ คือ ส่วนร่วมเฟส (In-phase Component) และ $Q(k, m)$ คือ ส่วนตั้งฉากเฟส (Quadrature Component)

2.2.3 โครงสร้างข้อมูล CSI ในระบบ MIMO หลายสายอากาศ (MIMO-CSI Data Structure)

ในระบบที่มีการติดตั้งสายอากาศฝั่งส่งจำนวน N_{tx} ต้น และสายอากาศฝั่งรับจำนวน N_{rx} ต้น แต่ละคู่สายอากาศจะได้รับชุดข้อมูล CFR บน K สับแคร้เรียร์ ทำให้มิติของข้อมูลเชิงพื้นที่และความถี่รวมมีขนาด $W = N_{tx} \times N_{rx} \times K$ สำหรับการนำข้อมูล CSI ไปประมวลผลด้วยปัญญาประดิษฐ์เพื่อการรู้จำตำแหน่งและการเคลื่อนไหว ข้อมูลส่วน I และ Q ของทุกคู่สายอากาศและสับแคร้เรียร์ ณ เวลา M ช่วงตัวอย่าง จะถูกนำมาจัดเรียงเป็นบล็อกข้อมูลเมทริกซ์ 2 มิติ

$$\text{CSI}_{\text{sample}} \in \mathbb{R}^{W \times 2M} \quad (2.3)$$

โครงสร้างนี้ช่วยให้โมเดลสามารถเรียนรู้ทั้งความสัมพันธ์เชิงพื้นที่ระหว่างสายอากาศ (Spatial Correlation) รูปแบบการตอบสนองความถี่ (Frequency Selectivity) และพลวัตการเปลี่ยนแปลงตามเวลา (Temporal Evolution) ได้อย่างสมบูรณ์

2.2.4 ความสัมพันธ์ระหว่าง CFR และ CIR (Transformation between Frequency and Time Domains)


ผลตอบสนองความถี่ของช่องสัญญาณ (CFR: $H(k, m)$) ในโดเมนความถี่ และผลตอบสนองเชิงอิมพัลส์ของช่องสัญญาณ (CIR: $h(n, m)$) ในโดเมนเวลากับความถี่ มีความสัมพันธ์กันผ่านการแปลงฟูเรียร์ไม่ต่อเนื่อง (DFT / IDFT)

$$h(n, m) = \frac{1}{\sqrt{N}} \sum_{k=0}^{N-1} H(k, m) e^{j \frac{2\pi}{N} nk}, \quad n = 0, 1, \dots, N-1 \quad (2.4)$$


การแปลง CFR ไปเป็น CIR ทำให้สามารถแยกแยะพลังงานและเวลาหน่วยของเส้นทางตรง (LOS) ออกจากเส้นทางสะท้อนหลายเส้นทาง (Multipath Components) ได้อย่างชัดเจน

2.3 Orthogonal Frequency Division Multiplexing

Orthogonal Frequency Division Multiplexing หรือ OFDM ช่วยให้สามารถส่งข้อมูลในอัตราที่สูงได้โดยการแบ่งคลื่นพาห်สัญญาณแบนด์วิดท์สูงที่ถูกมอดูเลตออกเป็นคลื่นพาห်ย่อยแบนด์วิดท์แคบที่ถูกมอดูเลตจำนวนมาก สำหรับการส่งสัญญาณแบบ OFDM การใช้คลื่นพาห်ย่อยแบนด์วิดท์แคบจะช่วยลดความไวต่อการจางหายแบบเลือกความถี่ (Frequency Selective Fading) มาตรฐานไร้สายและโทรคมนาคมล่าสุดหลายมาตรฐานใช้รูปแบบการมอดูเลตแบบหลายคลื่นพาห် OFDM การรองรับอัตราข้อมูลสูงในระบบคลื่นพาห်เดี่ยวจำเป็นต้องใช้คลื่นพาห်ที่มีแบนด์วิดท์กว้าง และส่งผลให้ช่วงเวลาของสัญญาณสั้นลง การกรองคลื่นพาห်ที่มีแบนด์วิดท์กว้างผ่านช่องสัญญาณหลายเส้นทางแบบเลือกความถี่ทำให้คุณภาพของสัญญาณลดลงอย่างรุนแรง เนื่องจากผลตอบสนองอิมพัลส์ของช่องสัญญาณครอบคลุมหลายสัญลักษณ์ในเวลา และทำให้สัญญาณมีความเสี่ยงต่อการรบกวนระหว่างสัญลักษณ์ (ISI) กราฟในโดเมนเวลาและโดเมนความถี่เหล่านี้แสดงสัญญาณอัตราต่ำ สัญญาณอัตราสูง และการตอบสนองของช่องสัญญาณหลายเส้นทางแบบเลือกความถี่ กราฟโดเมนเวลาแสดงให้เห็นว่าผลตอบสนองอิมพัลส์ของช่องสัญญาณสามารถถูกบรรจุอยู่ในหนึ่งสัญลักษณ์ของสัญญาณอัตราต่ำได้อย่างง่ายดาย แต่มันขยายครอบคลุมหลายสัญลักษณ์ของสัญญาณอัตราสูง กราฟโดเมนความถี่แสดงให้เห็นว่าขนาดของช่องสัญญาณนั้นราบเรียบมากตลอดช่วงพาสแบนด์ของสัญญาณอัตราต่ำ แต่มีความแปรปรวนอย่างมากตลอดช่วงพาสแบนด์ของสัญญาณอัตราสูงและก่อให้เกิด ISI




รูปที่ 2.1 กราฟโดเมนเวลาแสดงสัญญาณอัตราต่ำสูงและผลตอบสนองอิมพัลส์ของช่องสัญญาณ [1]




รูปที่ 2.2 กราฟความถี่แสดงสเปกตรัมของสัญญาณอัตราต่ำ สัญญาณอัตราสูง เทียบกับผลตอบสนองความถี่ของช่องสัญญาณ [1]

เพื่อหลีกเลี่ยง ISI ในขณะที่ยังส่งสัญญาณแบบดิจิทัลที่ต่ำแบบขนานกันจำนวนมาก คลื่นพาดย่อยแต่ละตัวจะต้องตั้งฉากซึ่งกันและกัน การหลีกเลี่ยง ISI โดยการส่งคลื่นพาดย่อยแบบดิจิทัลที่ต่ำที่ตั้งฉากกันจำนวนมากคือแรงจูงใจเบื้องหลัง OFDM ตัวมอดูเลต OFDM จะแปลงสตรึมของสัญลักษณ์แบบอนุกรมที่มีอัตราสูงให้เป็นสตรึมแบบขนานที่มีอัตราต่ำจำนวนมาก สตรึมอัตราต่ำที่ตั้งฉากกันแต่ละสตรึมจะพบกับช่องสัญญาณที่ค่อนข้างราบเรียบโดยมี ISI น้อยที่สุด และสามารถทำอีควอไลซ์ได้ง่าย เพื่อเป็นการสาธิตให้พิจารณาพัลส์ที่มีระยะเวลา $T_{sym} = 0.25$ วินาที อัตราข้อมูลสัญลักษณ์ $R_{sym} = 1/T_{sym} = 8\text{ Hz}$ และพัลส์

เพิ่มเติมที่ถูกเลื่อนความถี่ไปที่ พัลส์ที่ถูกเลื่อนความถี่เหล่านี้เรียกว่าคลื่นพายุย่อย กราฟเหล่านี้แสดงคลื่นพายุย่อยในโดเมนเวลาและโดเมนความถี่



รูปที่ 2.3 กราฟโดเมนเวลาของคลื่นพายุย่อย แสดงพัลส์ต้นแบบและพัลส์ที่ถูกเลื่อนความถี่ไปที่ R_{sym} , $2R_{sym}$ และ $3R_{sym}$ [1]



รูปที่ 2.4 กราฟโดเมนความถี่ของคลื่นพายุย่อย แสดงสเปกตรัมที่ตั้งฉากกันโดยมียอดของแต่ละคลื่นพายุย่อยตรงกับจุดตัดศูนย์ของคลื่นพายุย่อยอื่น [1]

กราฟโดเมนความถี่แสดงพัลส์ที่ถูกเลื่อนความถี่แบบตั้งฉากกัน โดยมียอดสเปกตรัมของคลื่นพาย่อยแต่ละตัวเกิดขึ้นที่จุดตัดศูนย์ของพัลส์อื่นๆ ทั้งหมด ตัวมอดูเลต OFDM จะรวมคลื่นพาย่อยทั้งหมดนี้เข้าด้วยกันเพื่อสร้างสัญญาณเอาต์พุต ในที่นี้ คลื่นพาย่อยถูกมอดูเลตแบบแบนด์โดยใช้วิธี QAM ในทางคณิตศาสตร์ สัญญาณเอาต์พุตของตัวมอดูเลตที่ถูกสุ่ม $s(k)$ ถูกกำหนดตามสมการที่ 2.5

$$s(k) = \sum_{m=0}^{N-1} a_{m,n} e^{\frac{j2\pi m R_{sym} k T_{sym}}{N}} \quad (2.5)$$

1) $a_{m,n}$ คือสัญลักษณ์ที่ถูกมอดูเลตแบบ QAM ของคลื่นพาย่อยที่ m ในสัญลักษณ์เวลา OFDM ที่ n

2) R_{sym} คือ อัตราสัญลักษณ์ของสตรีม QAM อัตราต่ำแต่ละสตรีม $T_{sym} = 1 / R_{sym}$

3) N คือ จำนวนคลื่นพาย่อย หรือสตรีม QAM อัตราต่ำ

ซึ่งสมการที่ 2.5 สามารถลดรูปได้เป็นสมการที่ 2.6 ซึ่งเป็นเวอร์ชันที่ถูกปรับขนาดของการแปลงฟูเรียร์แบบไม่ต่อเนื่องผกผัน (IDFT) ของสตรีมสัญลักษณ์ QAM $a_{m,n}$

$$s(k) = \sum_{m=0}^{N-1} a_{m,n} e^{\frac{j2\pi mk}{N}} \quad (2.6)$$

2.4 ทฤษฎีการหักล้างสัญญาณพื้นหลังและการแยกสัญญาณการเคลื่อนไหวของมนุษย์จากคลื่นไวไฟ (WiFi CSI Background Subtraction & Dynamic Motion Isolation)

2.4.1 แบบจำลองช่องสัญญาณและการแพร่กระจายหลายเส้นทาง (CSI Channel & Multipath Propagation Model)

ในระบบการสื่อสารไร้สายมาตรฐาน IEEE 802.11 WiFi สัญญาณคลื่นวิทยุจะถูกส่งผ่านกลไกการกล้ำสัญญาณแบบหลายพาหะย่อยเชิงตั้งฉาก (Orthogonal Frequency Division Multiplexing, OFDM) ข้อมูลสถานะช่องสัญญาณ (Channel State Information, CSI) ที่ฝั่งตัวรับสัญญาณวัดได้ คือค่าตอบสนองความถี่ของช่องสัญญาณ (Channel Frequency Response, CFR) ซึ่งเป็นผลรวมของการซ้อนทับกันของคลื่นวิทยุจากเส้นทางการแพร่กระจายหลายเส้นทาง (Multipath Propagation) จำนวน L เส้นทาง ทางคณิตศาสตร์ ข้อมูล CFR ณ สับแคร์เรียร์ลำดับที่ k ที่เวลาการรับส่งข้อมูล $t(m)$ สามารถเขียนแทนด้วยสมการ

$$H(k, m) = \sum_{l=0}^{L-1} \alpha_l(k, m) e^{-j2\pi f(k)\tau_l} \cdot e^{j2\pi t(m)v_l} \quad (2.7)$$

1) $\alpha_l(k, m)$ คือ ค่าการลดทอนของสัญญาณ (Attenuation) ในเส้นทางการแพร่กระจายที่ l ณ สับแครี่เรย์ลำดับที่ k ที่เวลา $t(m)$

2) τ_l คือ เวลาหน่วงในการเดินทางของคลื่นสัญญาณ (Propagation Delay) ในเส้นทาง l

3) v_l คือ ความถี่เลื่อนดอปเปลอร์ (Doppler Frequency Shift) ที่เกิดขึ้นจากการเคลื่อนไหวของวัตถุหรือมนุษย์ในเส้นทางที่ l

4) $f(k)$ คือ ความถี่พาหะย่อยของสับแครี่เรย์ลำดับที่ k

เมื่อนำข้อมูล CFR ไปผ่านการแปลงฟูเรียร์ไม่ต่อเนื่องแบบผกผัน (Inverse Discrete Fourier Transform, IDFT) ขนาด N จุด จะได้ค่าผลตอบสนองเชิงอิมพัลส์ของช่องสัญญาณ (Channel Impulse Response, CIR) ซึ่งสะท้อนคุณลักษณะทางกายภาพของเส้นทางสัญญาณในโดเมนเวลา ความหน่วง (Time Delay Domain)

$$h(n, m) = \frac{1}{\sqrt{N}} \sum_{k=0}^{N-1} \sum_{l=0}^{L-1} \alpha_l(k, m) e^{-j2\pi f(k)\tau_l} \cdot e^{j2\pi t(m)v_l} \cdot e^{j\frac{2\pi}{N}nk}, \quad n = 0, 1, \dots, N-1 \quad (2.8)$$

2.4.2 การคำนวณผลต่างเวกเตอร์เพื่อหักล้างสัญญาณสะท้อนสถิต (Vector-based Background Subtraction & Differential Residuals)

ในสภาพแวดล้อมภายในห้อง คลื่นสัญญาณ WiFi จะเดินทางผ่านแนวสายตาตรง (Line-of-Sight, LOS) และสะท้อนกับวัตถุที่อยู่นิ่ง เช่น ผนัง ประตู หน้าต่าง พื้นกระเบื้อง และกระจกเงา เกิดเป็น องค์ประกอบสัญญาณพื้นหลังสถิต (Static Environmental Component) ในขณะที่การเคลื่อนไหวของมนุษย์จะสร้าง เส้นทางสะท้อนแบบพลวัต (Dynamic Multipath Component)


1) การประมาณค่าสัญญาณพื้นหลังสถิต ($\hat{h}_0$) ในสภาวะที่ไม่มีเป้าหมายเคลื่อนไหว ข้อมูล CIR พื้นหลังสามารถหาได้จากการหาค่าเฉลี่ยของข้อมูล CIR จำนวน M ช่วงเวลา เพื่อลดทอนสัญญาณรบกวนสุ่มในการวัด

$$\hat{h}_0(n) = \frac{1}{M} \sum_{m=1}^M h(n, m) \quad (2.9)$$

2) การสกัดสัญญาณการเคลื่อนไหวของเป้าหมาย (h_{target}) เมื่อมีบุคคลเคลื่อนไหวยู่ในพื้นที่สัญญาณ CIR ที่วัดได้ (h_1) จะประกอบด้วยสัญญาณพื้นหลังสถิตรวมกับสัญญาณสะท้อนจากร่างกายมนุษย์ การหักล้างสัญญาณพื้นหลังจะดำเนินการผ่านการลบทางเวกเตอร์ (Vector Subtraction)


$$h_{\text{target}} = h_1 - h_0 \quad (2.10)$$

- กรณีเป้าหมายสร้างเส้นทางสะท้อนใหม่ สัญญาณ LOS และสัญญาณสะท้อนจากโครงสร้างสถิตเดิมจะถูกหักล้างออกไป เหลือเพียงยอดคลื่นสะท้อนใหม่ที่เกิดจากร่างกายมนุษย์



รูปที่ 2.5 แผนภาพช่องสัญญาณพื้นหลัง และช่องสัญญาณเป้าหมายกรณีเป้าหมายก่อให้เกิดพาธสะท้อนเพิ่มเติม [2]

- กรณีเป้าหมายบดบังเส้นทางเดิม การบดบังแนวสายตาตรง (LOS) หรือเส้นทางสะท้อนสถิต จะทำให้เกิดการกลับขั้วของเฟสและทิ้งค่าเศษเหลือเชิงอนุพันธ์ (Differential Residuals) ของการรบกวนคลื่นไวโน h_{target}




รูปที่ 2.6 แผนภาพช่องสัญญาณเป้าหมาย ในลักษณะสัญญาณตกค้างเชิงผลต่าง กรณีเป้าหมายบดบัง พารสายตรงและบดบังพารสะท้อน [2]

2.4.3 การชดเชยความคลาดเคลื่อนจากการซิงโครไนซ์ (Synchronization Residuals & Compensation Pipeline)


ในอุปกรณ์ WiFi ทั่วไป (Bistatic Configuration) ตัวส่งและตัวรับไม่ได้ใช้สัญญาณนาฬิกาเดียวกัน จึงเกิดความคลาดเคลื่อนหลัก 3 ประการ

- 1) Timing Offset (TO: τ_Δ) ความคลาดเคลื่อนของเวลาเริ่มต้นในการสุ่มตัวอย่าง
- 2) Timing Drift (TD: $\Delta\tau_m$) การเลื่อนลอยของสัญญาณนาฬิกาตามเวลา ซึ่งส่งผลให้ CIR เกิดการเลื่อนตำแหน่งเชิงวงรอบ (Cyclic Shift) ขนาด $\delta_m = k\Delta f\Delta\tau_m$ และเกิดการเลื่อนเฟสแบบสุ่ม $\Delta\phi_m = 2\pi\Delta f_{\text{CFO},m}\Delta\tau_m$
- 3) Carrier Frequency Offset (CFO: $\Delta f_{\text{CFO},m}$) ความคลาดเคลื่อนของความถี่ออสซิลเลเตอร์

ผลกระทบหากไม่ชดเชยสัญญาณเฟสของสัญญาณ CIR จะเกิดการกระจายตัวแบบสุ่มและกลับขั้วเฟส ทำให้เมื่อนำ CIR หลายชุดมาหาค่าเฉลี่ย $\hat{h}_0$ สัญญาณจะหักล้างกันเองจนแอมพลิจูดลู่เข้าสู่ศูนย์ ($\hat{h}_0 \rightarrow 0$) ทำให้ไม่สามารถสกัดสัญญาณพื้นหลังที่ถูกต้องได้



รูปที่ 2.7 กราฟเปรียบเทียบข้อมูล CSI ดิบในโดเมนความถี่ กับโดเมนดีเลย์ทั้งแอมพลิจูดและเฟส [2]




รูปที่ 2.8 กราฟ CIR เฉลี่ยจากการวัดหลายครั้งในโดเมนดีเลย์ แสดงผลของจำนวนค่าเฉลี่ยต่อสัญญาณ ตกค้างจากการซิงโครไนซ์ [2]

ขั้นตอนการชดเชยความคลาดเคลื่อนในระบบ BE-Fi

1) Oversampling IDFT นำ CFR ขนาด K สับแคร้เรียร์มาแปลงเป็น Super-Resolution CIR ด้วยอัตราการสุ่มตัวอย่างเกิน β เท่า (โดยเลือก $\beta = 8$) เพื่อเพิ่มความละเอียดในการระบุตำแหน่ง ยอดคลื่นหน่วยเวลา


$$\mathbf{h}_u(n, m) = \text{IDFT} \left\{ \left[H(k, m), 0_{1 \times (N-K)} \right]^T \right\}, \quad N = \beta K \quad (2.11)$$

2) Delay Spectrum Alignment เลื่อนตำแหน่งเชิงวงรอบ (Circular Shift) เพื่อจัดตำแหน่งยอดคลื่นอ้างอิง (LOS Peak) ของทุกชุดข้อมูลให้ตรงกัน




รูปที่ 2.9 แอมพลิจูดผลตอบสนองอิมพัลส์ของช่องสัญญาณ (CIR) หลังการจัดตำแหน่งโปรไฟล์ดีเลย์ [2]

3) LOS Phase Compensation หมุนเฟสของจุดยอดคลื่น LOS ให้เป็นศูนย์ และหมุนเฟสของจุดอื่น ๆ ใน CIR ตามมุมขดเคี้ยวของเส้นทาง LOS เพื่อกำจัดความคลาดเคลื่อนของเฟส



รูปที่ 2.10 เฟสของ CIR และสถิติเฟสของสัญญาณ LOS หลังการจัดตำแหน่งสเปกตรัมดีเลย์: (a) เฟสของ CIR หลังจัดตำแหน่งสเปกตรัมดีเลย์ (b) สถิติเฟส LOS [2]



รูปที่ 2.11 เฟสของ CIR และ CFR หลังการจัดตำแหน่งสเปกตรัมดีเลย์และการชดเชยเฟส: (a) เฟสของ CIR (b) เฟสของ CFR [2]

2.4.4 การแปลงข้อมูลกลับสู่โดเมนความถี่สำหรับการประมวลผลด้วย AI (CFR Feature Reconstruction)

เมื่อได้ข้อมูล h_{target} ผ่านการหักล้างสัญญาณพื้นหลังแล้ว ข้อมูลจะถูกแปลงกลับเป็น Channel Frequency Response (CFR) ผ่านการแปลง Downsampled DFT เพื่อควบคุมขนาดมิติของข้อมูล จากนั้นทำการจัดเรียงส่วนจริง (In-phase: I) และส่วนจินตภาพ (Quadrature: Q) ของทุกสายอากาศและสับแครี่เรียร์ให้เป็นเมทริกซ์ $\text{CSI}_{\text{sample}} \in \mathbb{R}^{W \times 2M}$ (โดย $W = N_{\text{tx}} \times N_{\text{rx}} \times K$) เพื่อใช้เป็นข้อมูลนำเข้าของโครงข่ายประสาทเทียมต่อไป

2.5 ทฤษฎีการปรับเทียบเฟสและการกำจัดความคลาดเคลื่อนทางฮาร์ดแวร์ในเครื่องรับส่งสัญญาณวิทยุ (Phase Offset Calibration in RF Transceivers)

2.5.1 สาเหตุและประเภทของความคลาดเคลื่อนทางเฟสในระบบรับส่งสัญญาณคลื่นวิทยุ (Classification of Phase Offsets)

ในการวัดค่าเฟสของสัญญาณคลื่นพาหะด้วยวงจรรับสัญญาณแบบควอดราเจอร์ซูเปอร์เฮเทอโรไดน์ (Quadrature Superheterodyne Receiver) ค่าเฟสที่วัดได้จริงจะได้รับผลกระทบจากความคลาดเคลื่อนของฮาร์ดแวร์ภายในระบบ ซึ่งแบ่งออกเป็น 3 ประเภทหลัก

1) ความคลาดเคลื่อนของเฟสแบบแปรผันตามเวลา (Time Varying Phase Offsets) เกิดจากความคลาดเคลื่อนของความถี่คลื่นพาหะ (Carrier Frequency Offset, CFO) และความคลาดเคลื่อนของความถี่ในการสุ่มตัวอย่าง (Sampling Frequency Offset, SFO) อันเนื่องมาจากออสซิลเลเตอร์ท้องถิ่น (Local Oscillator, LO) ของฝั่งส่งและฝั่งรับไม่มีการใช้อ้างอิงความถี่ร่วมกัน ทำให้เกิดการเลื่อนของเฟสเชิงเส้นตามเวลา

2) ความคลาดเคลื่อนของเฟสแบบคงที่เชิงระบบ (Time Invariant Systematic Phase Offsets) เกิดจากความไม่เท่ากันของเวลาหน่วงในวงจรฟรอนต์เอนด์ (RF Frontend Hardware Delays) ของสายอากาศแต่ละช่องสัญญาณ ($T_{\text{Tx}}, T_{\text{Rx}}$) ซึ่งก่อให้เกิดค่าชดเชยเฟสคงที่ $\theta_{\text{Tx}} = 2\pi f_{\text{LO}} T_{\text{Tx}}$ และ $\theta_{\text{Rx}} = 2\pi f_{\text{LO}} T_{\text{Rx}}$

3) ความคลาดเคลื่อนของเฟสแบบสุ่มคงที่ (Time Invariant Random Phase Offsets) เกิดจากเฟสเริ่มต้นที่ไม่แน่นอนและไม่สามารถทำซ้ำได้ (Non repeatable Initial Phase) ของวงจรล็อกเฟส (Phase-Locked Loop, PLL) ในตัวสังเคราะห์ความถี่ของแต่ละช่องสัญญาณ ซึ่งค่าเฟสเริ่มต้นนี้ ($\theta_{\text{LO,Tx}}, \theta_{\text{LO,Rx}}$) จะเปลี่ยนแปลงแบบสุ่มทุกครั้งที่มีการรีบูตหรือเริ่มการทำงานของอุปกรณ์ใหม่ แม้ว่าอุปกรณ์จะใช้อ้างอิงความถี่เดียวกันก็ตาม

2.5.2 แบบจำลองการคำนวณเฟสและการแปลงเชิงเส้นสำหรับ CFO/SFO (Phase Calculation & Linear Transformation)

ในโครงสร้างภาครับแบบซูเปอร์เฮเทอโรไดน์ สัญญาณแถบฐาน (Baseband) จะถูกมอดูเลตกับสัญญาณความถี่กลาง (Intermediate Frequency: IF) และอัปคอนเวิร์ตด้วยความถี่ f_{LO} ส่งผ่านช่องสัญญาณไร้สายที่มีการหน่วงเฟส θ_{air} ค่าเฟสรวมที่วัดได้จากสัญญาณดิจิทัล IF ผ่านฟังก์ชัน atan2 สามารถเขียนแทนด้วยสมการ

$$\theta_{total} \approx \theta_{Tx} + \theta_{air} + \theta_{Rx} + \theta_{LO,Rx} - \theta_{LO,Tx} \quad (2.12)$$

สำหรับการกำจัดความคลาดเคลื่อนแบบแปรผันตามเวลาที่เกิดจาก CFO และ SFO ในระบบมัลติเพล็กซ์แบบ OFDM หรือระบบหลายช่องสัญญาณ งานวิจัยในอดีตได้ใช้คุณสมบัติความสัมพันธ์เชิงเส้นระหว่างเฟสกับเวลาและดัชนีสับแครี่เรียร์ (Linear Phase-Time and Phase-Subcarrier Relationship) ในการทำ การแปลงเชิงเส้นและการประมาณค่าเชิงเส้น (Linear Transformation / Linear Fitting) เช่น Linear Minimum Mean Square Error (L-MMSE) เพื่อหักล้างความชันของเฟสที่เกิดจาก CFO/SFO อย่างไรก็ตาม การกำจัดความชันเชิงเส้นของ CFO/SFO จะยังคงหลงเหลือค่าคงที่ของเฟสที่ไม่ทราบค่า ซึ่งรวมอยู่กับความคลาดเคลื่อนของเฟสเริ่มต้นแบบสุ่ม (θ_{LO}) และความคลาดเคลื่อนเชิงระบบของฟรอนต์เอนด์ (θ_{Rx})

2.5.3 ทฤษฎีการปรับเทียบเฟสด้วยเฟสผลต่างและโมดูลเชื่อมต่อตัวแบ่งสัญญาณ (Differential Phase and SCM Calibration Method)

เมื่อทำการวัดเฟสผลต่างระหว่างสายอากาศตัวรับสองชุด (Rx1 และ Rx2) ที่รับสัญญาณจากตัวส่งเดียวกัน (Condition 1) สัญญาณเฟสผลต่าง θ_{Rx12} จะมีรูปแบบดังสมการ

$$\theta_{Rx12} = \theta_{total,Rx1} - \theta_{total,Rx2} = (\theta_{air,Rx1} - \theta_{air,Rx2}) + (\theta_{LO,Rx1} - \theta_{LO,Rx2}) + (\theta_{Rx1} - \theta_{Rx2}) \quad (2.13)$$

เพื่อกำจัดค่า $(\theta_{LO,Rx1} - \theta_{LO,Rx2})$ และ $(\theta_{Rx1} - \theta_{Rx2})$ โดยไม่ต้องพึ่งพาทรัพยากรแบนด์วิดท์ขนาดใหญ่หรือการประมวลผลเชิงการหาค่าเหมาะสมที่สุด (Optimization) Xu & Kan (2023) ได้เสนอกระบวนการปรับเทียบ 3 ขั้นตอน

1) ขั้นตอนที่ 1 การวัดค่าโมดูลตัวแบ่งสัญญาณ (Splitter-Connection Module: SCM Measurements) ทำการวัดค่าผลต่างเฟสคงที่ของอุปกรณ์ต่อพ่วงภายนอก ($\theta_{SCM,out,m} - \theta_{SCM,out,n}$) และผลต่างเชิงระบบของพรีแอมป์ ($\theta_{Rxm} - \theta_{Rxn}$) เพียงครั้งเดียวผ่านการสลับพอร์ต (Port Swapping) บนคู่ตัวรับที่ใช้ LO ร่วมกัน

2) ขั้นตอนที่ 2 การวัดความคลาดเคลื่อนของเฟสโดยตรง (Direct Phase Offset Measurements) ส่งสัญญาณผ่านวงจร SCM ภายนอกเพื่อวัดค่าผลต่างเฟสที่ไม่พึงประสงค์ ($\theta_{nonideal,mn}$) ของแต่ละคู่ตัวรับที่มี LO แยกอิสระ


$$\theta_{nonideal,mn} = \theta_{Rxmn,step II} - (\theta_{SCM,out,m} - \theta_{SCM,out,n}) \quad (2.14)$$

3) ขั้นตอนที่ 3: การหักล้างและชดเชยเฟส (Phase Offset Correction) สลับการส่งสัญญาณไปยังช่องสัญญาณไร้สายจริง จากนั้นนำค่า $\theta_{nonideal,mn}$ ที่วัดได้จากขั้นตอนที่ 2 มาลบออกจากเฟสผลต่างที่วัดได้ในช่องสัญญาณไร้สาย ($\theta_{Rxmn,step III}$)

$$\theta_{air,Rxm} - \theta_{air,Rxn} = \theta_{Rxmn,step III} - \theta_{nonideal,mn} \quad (2.15)$$

2.5.4 ประสิทธิภาพของการปรับเทียบเฟสและความแม่นยำในการระบุพิภัก (Calibration Performance & Ranging Accuracy)

ผลการทดสอบเชิงประจักษ์บนแพลตฟอร์ม Software Defined Radio (USRP B210) ยืนยันว่า กระบวนการปรับเทียบเฟสสามารถลดความผันแปรของเฟสที่เกิดจากการรีบูตเครื่องให้มีค่าเบี่ยงเบนมาตรฐานน้อยกว่า 2 องศา (Standard Deviation $< 2^\circ$) ซึ่งเทียบเท่ากับความคลาดเคลื่อนในการวัดระยะทางในอากาศที่ความถี่ 1.8 GHz เพียง 0.9 มิลลิเมตร (0.9 mm Ranging Accuracy) ซึ่งมอบความเสถียรและความแม่นยำสูง



รูปที่ 2.12 กราฟบอกซ์พล็อตแสดงการกระจายตัวของผลต่างเฟสของแต่ละคู่สายอากาศตัวรับ ก่อนและหลังการปรับเทียบเฟส พร้อมภาพขยายรอบค่ามัธยฐานหลังปรับเทียบ [3]

2.6 ทฤษฎีการกรองสัญญาณความถี่ต่ำผ่านแบบบัตเตอร์เวิร์ธ (Butterworth Low-Pass Filtering in WiFi CSI Sensing)

2.6.1 องค์ประกอบของสัญญาณรบกวนในข้อมูล WiFi CSI (Noise Components in CSI Measurements)

ในการเก็บรวบรวมข้อมูลสถานะช่องสัญญาณ CSI ผ่านอุปกรณ์ WiFi สัญญาณที่ได้รับจริงจะประกอบด้วยสัญญาณจริงจากการแพร่กระจายของคลื่นวิทยุ รวมกับสัญญาณรบกวนจากการวัด (Measurement Noise)

$$\hat{H}(k, t) = H(k, t) + n(k, t) \quad (2.16)$$

โดยที่ $n(k, t) \sim \mathcal{CN}(0, \sigma_n^2)$ คือ สัญญาณรบกวนเกาส์เซียนเชิงซ้อน (Complex Gaussian Measurement Noise) ซึ่งมีแหล่งกำเนิดหลัก 2 ส่วน

1) สัญญาณรบกวนความร้อน (Thermal Noise): สัญญาณรบกวนสุ่มที่กระจายตัวอยู่ในย่านความถี่สูง

2) สัญญาณรบกวนจากฮาร์ดแวร์ (Hardware-Induced Noise): ความผันผวนของวงจรขยายสัญญาณอัตโนมัติ (Automatic Gain Control, AGC) และการรบกวนของวงจรออสซิลเลเตอร์ เมื่อทำการแยกองค์ประกอบของช่องสัญญาณออกเป็น ส่วนสถิตและส่วนพลวัต $H(k,t) = H_s(k) + H_d(k,t)$ โดยที่ $H_s(k)$ คือสัญญาณสะท้อนพื้นหลังสถิต และ $H_d(k,t)$ คือสัญญาณที่เกิดจากการเคลื่อนไหวของมนุษย์ (Dynamic Human Motion Component) สัญญาณการเคลื่อนไหวของมนุษย์ เช่น การเดิน การเปลี่ยนอิริยาบถ หรือการล้ม จะมีการเปลี่ยนแปลงความถี่ดอปเพลอร์ (Doppler Frequency Shift) อยู่ในย่านความถี่ต่ำ (Low Frequency Bands โดยทั่วไปต่ำกว่า 50–100 Hz ขึ้นอยู่กับอัตราการสั่นตัวอย่าง) ในขณะที่สัญญาณรบกวนทางความร้อนจะปรากฏในย่านความถี่สูง

2.6.2 หลักการทำงานและแบบจำลองทางคณิตศาสตร์ของตัวกรองบัตเตอร์เวิร์ธ (Butterworth Low-Pass Filter Model)

ตัวกรองความถี่ต่ำผ่านแบบบัตเตอร์เวิร์ธ (Butterworth Low Pass Filter) มีคุณสมบัติเด่น คือเป็นตัวกรองสัญญาณดิจิทัลที่มีผลตอบสนองขนาดความถี่ราบเรียบที่สุดในแถบส่งผ่าน (Maximally Flat Passband Response) โดยไม่มีการกระเพื่อมของสัญญาณ (No Passband Ripple) จึงช่วยรักษารูปคลื่นและคุณลักษณะเฉพาะของการเคลื่อนไหวของมนุษย์ (Motion Specific Features) ไม่ให้เกิดความผิดเพี้ยน ผลตอบสนองขนาดทางความถี่ (Frequency Magnitude Response) ของตัวกรองบัตเตอร์เวิร์ธลำดับที่ n แสดงได้ดังสมการ

$$|H_{bw}(f)|^2 = \frac{1}{1 + \left(\frac{f}{f_c}\right)^{2n}} \quad (2.17)$$

- 1) f คือ ความถี่ของสัญญาณ CSI
- 2) f_c คือ ความถี่ตัด (Cutoff Frequency) ซึ่งถูกปรับตั้งตามย่านความถี่ดอปเพลอร์ของการเคลื่อนไหวของมนุษย์ เพื่อตัดสัญญาณรบกวนความถี่สูงออก
- 3) n คือ ลำดับชั้นของตัวกรอง (Filter Order) ซึ่งกำหนดความชันในการลดทอนสัญญาณในแถบหยุด (Stopband Attenuation Rate)

2.6.3 การบูรณาการตัวกรองในกระบวนการขจัดสัญญาณรบกวน (Integrated Filtering Pipeline)

ในระบบตรวจจับและรู้จำกิจกรรมมนุษย์ด้วยคลื่น WiFi ตัวกรองแบตเตอรี่เวิร์ธความถี่ต่ำผ่าน จะถูกนำมาใช้งานร่วมกับเทคนิคอื่น ๆ เป็นกระบวนการประมวลผลสัญญาณเบื้องต้นแบบผสมผสาน (Hybrid Filtering Pipeline)

1) การกำจัดสัญญาณรบกวนแบบอิมพัลส์ (Impulse Noise Removal) ใช้ตัวกรองแฮมเพิล (Hampel Filter) เพื่อขจัดจุดข้อมูลผิดปกติ (Outliers) ออกจากลำดับแอมพลิจูดของ CSI

2) การกรองความถี่ต่ำผ่าน (Low-Pass Filtering) ใช้ตัวกรองแบตเตอรี่เวิร์ธเพื่อกำจัดสัญญาณรบกวนความร้อนและสัญญาณรบกวนความถี่สูง โดยยังคงรักษารูปคลื่นการเคลื่อนไหวของมนุษย์ ในย่านความถี่ต่ำไว้อย่างสมบูรณ์

3) การลดมิติข้อมูล (Dimensionality Reduction) ประยุกต์ใช้การวิเคราะห์องค์ประกอบหลัก เพื่อคัดเลือกและบีบอัดสับแคร์เรียร์ที่มีนัยสำคัญต่อการเคลื่อนไหว ลดความซับซ้อนในการคำนวณ และเพิ่มอัตราส่วนสัญญาณต่อสัญญาณรบกวน

2.6.4 การประนีประนอมประสิทธิภาพและความทนทานต่อสภาพแวดล้อม (Performance Trade-offs)

การใช้ตัวกรองแบบดั้งเดิม เช่น ตัวกรองแบตเตอรี่เวิร์ธ มีข้อได้เปรียบสำคัญคือ ความซับซ้อนในการคำนวณต่ำ (Low Computational Overhead) และมีความเสถียรสูง เหมาะสำหรับการประมวลผลแบบเรียลไทม์บนอุปกรณ์ประมวลผลขอบ (Edge Devices) เมื่อนำไปใช้งานร่วมกับตัวกรองสถิติและกระบวนการหักล้างสัญญาณพื้นหลัง จะช่วยเพิ่มค่า SNR ส่งผลให้ระบบตรวจจับการล้มและการเคลื่อนไหวสามารถสกัดแวกเตอร์คุณลักษณะที่มีความแม่นยำสูงก่อนป้อนเข้าสู่โมเดลปัญญาประดิษฐ์

2.7 Doppler Effect

ปรากฏการณ์ดอปเพลอร์ หรือการเลื่อนดอปเพลอร์ คือการเปลี่ยนแปลงที่ปรากฏของความถี่คลื่น โดยอิงจากการเคลื่อนที่สัมพัทธ์ของแหล่งกำเนิดและตำแหน่งของผู้สังเกต มันประยุกต์ใช้ได้กับคลื่นทุกประเภท รวมถึงคลื่นน้ำ คลื่นเสียง และคลื่นแม่เหล็กไฟฟ้า เช่น แสงที่มองเห็นได้ การประยุกต์ใช้ปรากฏการณ์ดอปเพลอร์ที่คุ้นเคยที่สุดเกี่ยวข้องกับเสียง โดยเฉพาะเสียงที่มาจกแหล่งกำเนิดที่กำลังเคลื่อนที่ (หรือเดินทางมาถึงผู้สังเกตที่กำลังเคลื่อนที่) เสียงที่คงที่ กล่าวคือ โน้ตเดี่ยวที่ตั้งต่อเนื่องสามารถปรากฏให้เห็นว่ามีการเปลี่ยนระดับเสียงได้เมื่อแหล่งกำเนิดเคลื่อนที่เมื่อเทียบกับผู้ฟัง เมื่อระยะห่างระหว่างแหล่งกำเนิดเสียงและผู้รับสั้นลง ความถี่ของคลื่นเสียงจะเพิ่มขึ้น ทำให้เสียงมีระดับเสียงที่สูงขึ้น และเมื่อระยะห่างยาวขึ้น ความถี่จะลดลง ทำให้เสียงมีระดับเสียงที่ต่ำลง สิ่งสำคัญที่ควรทราบคือสิ่งที่

เปลี่ยนไปคือการรับรู้เสียงของผู้สังเกต ไม่ใช่ตัวเสียงเอง ความถี่ของเสียงที่ถูกปล่อยออกมายังคงเท่าเดิม แต่ความถี่ที่ได้รับจะเปลี่ยนไปตามความเร็วและระยะห่างที่เพิ่มขึ้นหรือลดลงระหว่างแหล่งกำเนิดและผู้ฟัง

2.8 The Short Time Fourier Transform

การแปลงฟูเรียร์ระยะสั้น (The Short Time Fourier Transform, STFT) คือตัวดำเนินการเชิงเส้นที่สำคัญยิ่งสำหรับการวิเคราะห์ความสัมพันธ์ระหว่างเวลาและความถี่ของสัญญาณที่ไม่คงที่ โดยใช้ฟังก์ชันหน้าต่างเฉพาะที่เลื่อนไปตามคาบสัญญาณเพื่อคำนวณการแปลงฟูเรียร์ แก่นปัญหาสูงสุดของการใช้งาน STFT คือความจำเป็นในการหาจุดสมดุล (Trade Off) ระหว่างความละเอียดด้านเวลาและความถี่ ซึ่งถูกจำกัดด้วยขอบเขตของหลักความไม่แน่นอน กล่าวคือหน้าต่างวิเคราะห์ขนาดสั้นจะให้ความละเอียดทางเวลาสูงแต่แยกแยะความถี่ได้ต่ำ ในขณะที่หน้าต่างขนาดยาวจะให้ผลลัพธ์ที่ตรงกันข้าม เพื่อทลายข้อจำกัดเชิงสถาปัตยกรรมนี้ในงานวิศวกรรมขั้นสูง จึงมีการพัฒนา STFT ที่สามารถหาอนุพันธ์ได้ (Differentiable STFT) ซึ่งช่วยให้ระบบสามารถปรับขนาดพารามิเตอร์ของหน้าต่างและการเลื่อนเฟรมได้แบบอัตโนมัติตามโครงสร้างของข้อมูล ทำให้สามารถนำไปบูรณาการเรียนรู้ร่วมกับน้ำหนักของโครงข่ายประสาทเทียมได้อย่างสมบูรณ์แบบ นอกจากนี้ยังมีการใช้เทคนิคขั้นสูง เช่น การแปลงแบบบีบอัดเชิงโคโร (SST) เพื่อลดการแทรกสอดทางสเปกตรัมและสกัดวิถีความถี่ขณะใดขณะหนึ่งให้มีความคมชัดสูงสุดในทางปฏิบัติ STFT ถือเป็นเครื่องมือรากฐานที่ขาดไม่ได้และถูกประยุกต์ใช้อย่างทรงพลังในเทคโนโลยีสมัยใหม่ ตั้งแต่การสร้างโวลโคเดอร์เสียงประสาทเทียม การเข้ารหัสสเปกตรัม ไปจนถึงการประมวลผลสัญญาณด้วยระบบโพโตนิคส์ความเร็วสูงที่สามารถก้าวข้ามขีดจำกัดแบนด์วิดท์ของฮาร์ดแวร์อิเล็กทรอนิกส์แบบดั้งเดิมได้อย่างสิ้นเชิง

2.9 Spectrogram

กราฟที่แสดงความแรงของสัญญาณเมื่อเวลาผ่านไปสำหรับช่วงความถี่ที่กำหนด โดยจะใช้สเปกตรัมสีเพื่อชี้ให้เห็นถึงความถี่ที่สัญญาณมีพลังงานสูงสุด และแสดงการเปลี่ยนแปลงของพลังงานเมื่อเวลาผ่านไป สำหรับสัญญาณความถี่ต่อเนื่อง สเกลสีของสเปกโตรแกรมจะระบุความถี่ของจุดสูงสุดของแอมพลิจูด (Amplitude peaks) ของรูปคลื่นเมื่อเวลาผ่านไป สเปกโตรแกรมจะเชื่อมโยงค่าสูงสุดเข้ากับทั้งเวลาและความถี่ ซึ่งแตกต่างจากกราฟเวลาหรือกราฟความถี่ทั่วไป วิศวกรทดสอบการสั่นสะเทือนใช้สเปกโตรแกรมเพื่อวิเคราะห์องค์ประกอบความถี่ของรูปคลื่นแบบต่อเนื่อง เพื่อหาตำแหน่งของสัญญาณที่แรง และพิจารณาว่าพฤติกรรมการสั่นสะเทือนเปลี่ยนแปลงไปอย่างไรเมื่อเวลาผ่านไป ในการสร้าง

สเปกโตรแกรม ซอฟต์แวร์วิเคราะห์สัญญาณจะแบ่งสัญญาณในโดเมนเวลา (Time-domain signal) ออกเป็นส่วนๆ ที่มีความยาวเท่ากัน จากนั้นจะทำการแปลงฟูเรียร์อย่างรวดเร็ว (Fast Fourier Transform, FFT) กับแต่ละส่วน เพื่อแปลงข้อมูลจากโดเมนเวลาไปสู่โดเมนความถี่ สเปกโตรแกรมก็คือพล็อตของค่า FFT ในแต่ละส่วนนั่นเอง พารามิเตอร์จำนวนเฟรม (Frame Count) จะเป็นตัวกำหนดจำนวนของ FFT ที่โปรแกรมใช้ในการสร้างสเปกโตรแกรม ซึ่งจะส่งผลถึงปริมาณของสัญญาณเวลาโดยรวมที่จะถูกแบ่งออกเป็น FFT ที่เป็นอิสระต่อกัน ตัวอย่างเช่น เป็นไปได้ที่จะกำหนดสเปกโตรแกรมครอบคลุมระยะเวลา 10 ชั่วโมงด้วยเฟรม FFT เพียง 10 เฟรม อย่างไรก็ตาม มันจะทำให้เกิดช่องโหว่มากมายระหว่างการวิเคราะห์ FFT แต่ละครั้ง ในทางกลับกัน สเปกโตรแกรมระยะเวลา 1 นาทีที่มี 1,000 FFTs จะครอบคลุมตัวอย่างเวลาทั้งหมด โดยมีการซ้อนทับกันบางส่วน (Overlap) ระหว่างการวิเคราะห์

2.10 ทฤษฎีอินเทอร์เน็ตของสรรพสิ่งผสานปัญญาประดิษฐ์ (Artificial Intelligence of Things: AIoT)

2.10.1 นิยามและแนวคิดพื้นฐานของ AIoT (Concept and Fundamentals of AIoT)

การหลอมรวมระหว่างเทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence: AI) และ อินเทอร์เน็ตของสรรพสิ่ง (Internet of Things, IoT) หรือที่เรียกว่า Artificial Intelligence of Things (AIoT) เป็นวิวัฒนาการสำคัญของระบบดิจิทัลอัจฉริยะ โดย IoT ทำหน้าที่เป็นระบบประสาทสัมผัสในการเชื่อมต่ออุปกรณ์ เก็บข้อมูล และแลกเปลี่ยนข้อมูลจากสภาพแวดล้อมทางกายภาพ ในขณะที่ AI ทำหน้าที่เป็นสมองในการวิเคราะห์รูปแบบข้อมูล การเรียนรู้เชิงลึก และการตัดสินใจแบบอัตโนมัติ การผสานสองเทคโนโลยีเข้าด้วยกันช่วยยกระดับระบบจากการเก็บข้อมูลแบบตั้งรับ (Passive Data Collection) ไปสู่ระบบที่สามารถ รับรู้บริบท (Context-Aware Computing) สามารถประมวลผลตอบสนองได้แบบเรียลไทม์ (Real-Time Responsiveness) และสามารถปรับแต่งการทำงานได้ด้วยตนเอง (Self-Optimization) ซึ่งช่วยลดการพึ่งพามนุษย์และเพิ่มประสิทธิภาพการทำงานในสภาพแวดล้อมที่มีความเปลี่ยนแปลงตลอดเวลา

2.10.2 สถาปัตยกรรมเชิงชั้นและแบบกระจายตัวของระบบ AIoT (Layered and Distributed AIoT Architectures)

ระบบ AIoT สมัยใหม่ถูกออกแบบภายใต้สถาปัตยกรรมแบบลำดับชั้นและการประมวลผลแบบกระจายตัว (Hybrid and Distributed Architectures) เพื่อแก้ไขปัญหาคอขวดด้านความหน่วง (Latency) แบนด์วิดท์ และความเป็นส่วนตัวของข้อมูล ซึ่งประกอบด้วยชั้นหลักดังนี้

1) ชั้นการรับรู้และการตรวจวัด (Perception / Sensing Layer) ประกอบด้วยอุปกรณ์ IoT ฮาร์ดแวร์ไมโครคอนโทรลเลอร์ และเซนเซอร์ตรวจวัดทางกายภาพ ทำหน้าที่เก็บข้อมูลดิบจากสิ่งแวดล้อม เช่น ข้อมูลคลื่นวิทยุ CSI หรือสัญญาณการเคลื่อนไหว

2) ชั้นเครือข่ายและการส่งผ่านข้อมูล (Network & Transmission Layer) ใช้โปรโตคอลการสื่อสารที่มีน้ำหนักเบาและประหยัดพลังงาน (เช่น MQTT, CoAP, AMQP) ร่วมกับเทคโนโลยีเครือข่ายไร้สายความเร็วสูง (เช่น WiFi, 5G/6G) เพื่อส่งผ่านข้อมูลแบบเรียลไทม์ด้วยความหน่วงต่ำและมีความน่าเชื่อถือสูง

3) ชั้นการประมวลผลอัจฉริยะแบบกระจายศูนย์ (Edge, Fog, and Cloud Intelligence Layer)

- การประมวลผลขอบ (Edge Computing / Edge AI) นำโมเดล AI ที่ผ่านการบีบอัดขนาด (Model Compression) ไปประมวลผลและอนุมานผล (Inference) บนอุปกรณ์ขอบหรือเกตเวย์โดยตรง ช่วยลดความหน่วงให้อยู่ในระดับมิลลิวินาที ประหยัดแบนด์วิดท์ และเพิ่มความปลอดภัยของข้อมูลเนื่องจากข้อมูลดิบไม่ต้องถูกส่งออกจากพื้นที่
- การประมวลผลบนคลาวด์และเซิร์ฟเวอร์ประสิทธิภาพสูง (Cloud / Server Computing) ทำหน้าที่เป็นศูนย์กลางในการฝึกสอนโมเดลขนาดใหญ่ (Model Training) การจัดเก็บข้อมูลประวัติระยะยาว และการวิเคราะห์เชิงลึกของระบบ

4) ชั้นการประยุกต์ใช้งานและการติดต่อผู้ใช้ (Application Layer) การนำผลลัพธ์จากการอนุมานของ AI ไปแสดงผลบนเว็บแอปพลิเคชัน แดชบอร์ดสำหรับผู้ดูแล และระบบส่งสัญญาณแจ้งเตือนเหตุการณ์ฉุกเฉินแบบอัตโนมัติ

2.10.3 การประยุกต์ใช้ AIoT ในระบบสุขภาพและการเฝ้าระวังผู้สูงอายุ (AIoT in Smart Healthcare and Safety Monitoring)

ในมิติด้านการแพทย์และการดูแลสุขภาพ (Smart Healthcare) AIoT มีบทบาทสำคัญในการพัฒนาระบบเฝ้าระวังผู้ป่วยและผู้สูงอายุระยะไกล (Remote Patient Monitoring) โดยระบบสามารถตรวจจับความผิดปกติ (Anomaly Detection) จากข้อมูลอนุกรมเวลา (Time-Series Data) ของการเคลื่อนไหวและสัญญาณชีพได้อย่างต่อเนื่อง จุดเด่นสำคัญของการประยุกต์ใช้ AIoT ในงานเฝ้าระวังคือ

1) การแจ้งเตือนอุบัติเหตุแบบทันที่ (Preemptive and Timely Alerts) อัลกอริทึมการเรียนรู้เชิงลึกสามารถจำแนกพฤติกรรมเสี่ยงหรืออุบัติเหตุการหกล้ม และส่งสัญญาณเตือนไปยังบุคลากรทางการแพทย์หรือผู้ดูแลได้ทันทีภายในช่วงเวลาสำคัญ (Golden Hour)

2) การรักษาความเป็นส่วนตัวของข้อมูลผู้ใช้งาน (Privacy Preservation) การผสมผสาน Edge AI ช่วยให้การวิเคราะห์พฤติกรรมเกิดขึ้นภายในระบบท้องถิ่น โดยไม่ต้องพึ่งพากล้องวิดีโอหรือส่งภาพเคลื่อนไหวที่ละเมิดความเป็นส่วนตัว ซึ่งสอดคล้องกับมาตรฐานความปลอดภัยของข้อมูลส่วนบุคคล (เช่น GDPR และ HIPAA)

2.10.4 การจัดการวงจรชีวิตของโมเดล AI บนอุปกรณ์ IoT (AI Lifecycle Management in IoT)

เพื่อให้ระบบ AIoT สามารถทำงานได้อย่างมีประสิทธิภาพและต่อเนื่อง จำเป็นต้องมีกระบวนการจัดการวงจรชีวิตของโมเดล AI (AI Lifecycle Management) ซึ่งประกอบด้วย

1) การฝึกสอนและตรวจสอบความถูกต้องของโมเดล (Model Training and Validation) การพัฒนาและทดสอบประสิทธิภาพโมเดลบนชุดข้อมูลอนุกรมเวลา

2) การบีบอัดโมเดลเพื่อการติดตั้งใช้งาน (Model Compression and Deployment): การใช้เทคนิคการตัดแต่งกิ่งโครงข่าย (Pruning) การควอนไทเซชัน (Quantization) และการกลั่นกรององค์ความรู้ (Knowledge Distillation) เพื่อให้โมเดลมีขนาดเล็กและใช้พลังงานต่ำ เหมาะสมกับการทำงานบนฮาร์ดแวร์จำกัดทรัพยากร

3) การติดตามและปรับปรุงโมเดล (Model Monitoring and Governance): การตรวจวัดประสิทธิภาพเพื่อป้องกันปัญหาการเสื่อมถอยของโมเดล (Model Drift) เมื่อสภาพแวดล้อมทางกายภาพเปลี่ยนแปลงไป